

研究周报

一、研究内容

(一)文生文

1. 《Plan-And-Write: Towards Better Automatic Storytelling》

发表信息：AAAI Conference on Artificial Intelligence (AAAI)

研究介绍：这篇论文针对自动叙事生成中常见的逻辑混乱和内容贫乏问题，提出了“**先规划，后写作**”的分层生成框架。

研究贡献：

1. “规划 - 写作”的分层框架

- **核心理念**：作者认为直接从标题生成故事（端到端）就像“即兴演讲”，容易跑题。因此，他们引入了一个中间层——**情节规划**。
- **价值**：这在当时主要由RNN/LSTM主导的生成模型中，引入了类似人类写作的“列提纲”思维，显著提升了故事的结构性。

2. 探索并对比了两种规划策略

- **动态规划**：边写边规划。每生成一句话，就规划下一句话的关键词。模拟的是即兴创作。
- **静态规划**：全盘规划。先一次性把整篇故事的关键词大纲列好，再根据大纲写全文。模拟的是深思熟虑的写作。
- **结论**：实验证明，静态规划（先列全大纲）在连贯性和相关性上表现更好；动态规划虽然灵活，但容易在结尾处偏离轨道。

学习与应用：本人机协同小说生成系统参考该论文研究贡献，后端框架使用“梗概 - 设定 - 大纲 - 正文”的结构化创作流程。目前本系统生成文本整体逻辑连贯，对比市面上动态规划生成小说的产品，生成文本质量较佳。

(二)文生图

1. 《StoryDiffusion: Consistent Story Visualization with Diffusion Models》

发表信息：2023 CVPR 研讨会，叙事图像生成顶流论文

研究背景：传统文生图模型仅支持单张独立图片生成，在连续故事、长篇小说多章节配图场景中，极易出现人物形象突变、场景风格割裂、剧情画面逻辑脱节等问题，无法满足叙事类图文配套需求。该论文专门针对连贯故事序列图像生成展开研究，适配小说逐章配图场景。

核心详细技术点

(1) 故事层级文本拆解机制

将完整长篇小说按照章节、段落、场景镜头三层拆分，摒弃全文直接输入的方式，精准划分独立叙事单元，让模型逐段匹配画面，避免长文本语义混乱。

(2) 全局角色特征缓存库构建

首次出现小说主角、配角、特殊物象时，自动提取人物外貌、服饰、体型、神态视觉特征，存入专属特征向量库；后续所有章节生成图像时，强制调用该特征库，从底层锁定人物外观，杜绝“同人不同貌”。

(3) 上下文叙事特征继承

引入前一章节生成图像的视觉特征与文本语义作为前置条件，生成下一章节画面时，继承场景氛围、色调、画风、构图习惯，保证整本小说配图视觉风格统一。

(4) 剧情动作语义对齐模块

深度解析小说内人物动作、互动关系、环境变化，将文字剧情动作转化为图像空间姿态，让画面严格贴合章节剧情走向，不出现剧情偏离画面。

(5) 风格统一约束损失函数

在扩散模型迭代过程中加入风格约束损失，统一整本小说插画的画风（古风 / 现代 / 奇幻等），不会出现前一章写实、后一章二次元的割裂问题。

学习收获与项目应用

学习到连贯叙事图像生成的核心逻辑，明确小说逐章配图最大难点为人物一致性与画风连贯性。项目中可借鉴该思路：拆分小说章节场景、固定主角视觉特征、继承上一章画面风格，实现整本小说成套统一插画生成。

2. 《LLM-Guided Story Visualization with Diffusion Models》

发表信息：2023 arXiv 预印本，大模型赋能故事图文生成经典论文

研究背景：用户撰写的小说文本口语化强、语句冗长、描写分散，包含大量心理描写、对话描写，无法直接作为 AI 绘画输入提示词，普通文本直接生成图片效果极差。该论文提出用大语言模型作为中间转换器，完成小说文本到标准绘画提示词的精准转化。

核心详细技术点

(1) 多维度小说文本结构化解析

依托大语言模型对小说内容进行四维拆解：人物设定、世界观环境、情节事件、情感氛围，自动剔除无视觉价值的内心独白、冗余对话，只保留可可视化内容。

(2) 层级化绘画 Prompt 重构

将拆解后的视觉信息按照「主体人物 + 环境场景 + 动作姿态 + 光影色调 + 艺术风格 + 画质参数」固定格式重组，生成符合扩散模型输入规范的专业长提示词。

(3) 世界观全局风格锚定

提前读取用户预设的小说世界观（仙侠、都市、末世、校园等），自动批量注入风格关键词，统一所有章节配图的整体美术基调。

(4) 自动生成反向负面提示词

根据小说剧情场景，自动匹配负面关键词，规避画面崩坏、人物畸形、构图错乱、场景违和等常见生图缺陷。

(5) 章节情绪色调适配

识别章节剧情情绪（悲伤、热血、温馨、压抑），自动搭配对应冷暖色调、光影氛围，让画面情绪贴合文字剧情。

学习收获与项目应用

掌握小说原始文本标准化预处理流程，解决项目中长篇小说文字杂乱、无法直接生图的痛点。项目中采用该方案：先用大模型清洗优化章节文本，转化为标准绘画提示词，再调用图像模型生成配图，大幅提升画面贴合度。

3. 《Long-CLIP: Unlocking Long Textual Descriptions for Text-to-Image Generation》

发表信息：2023 arXiv，长文本图文对齐核心论文

研究背景：常规 CLIP 图文对齐模型仅适配短句子、短句描述，面对小说单章节上千字长文本时，会出现关键视觉信息被稀释、核心人物场景权重降低、长尾描写覆盖主体内容等问题，导致生成画面偏离章节核心内容。

核心详细技术点

(1) 长文本分片分段编码策略

将整章超长小说文本切分为多个短语义片段，分别完成文本特征编码，解决单一长文本编码溢出、语义丢失问题。

(2) 全局语义融合聚合算法

对所有分片文本特征进行全局融合汇总，保留全文整体剧情逻辑，避免分段生成导致画面碎片化、剧情断裂。

(3) 视觉实体关键词加权增强

自动识别文本内人物、建筑、道具、自然场景等高视觉权重实体词汇，提升其特征占比；弱化心理活动、旁白议论等低权重文字影响力。

（4）冗余语义过滤过滤机制

设置文本筛选阈值，自动删减重复描写、抒情语句、叙事铺垫等无画面价值内容，浓缩核心可视化信息。

（5）长短文本自适应对齐

兼容短句人设设定与长句章节正文两种输入形式，适配项目中“前期角色设定 + 后期长篇章节”双重文本输入场景。

学习收获与项目应用

理解长文本图文匹配的技术难点与优化方案，解决项目中单章节大篇幅小说文本生图信息跑偏问题。项目中运用该技术思路，对章节正文进行权重筛选与精简编码，保证 AI 精准抓住章节核心画面进行生成。

4. 《ControlNet: Adding Conditional Control to Text-to-Image Diffusion Models》

发表信息：2023 CVPR 顶会论文，可控文生图奠基性论文

研究背景：传统扩散模型自由生成画面自由度过高，无法精准控制人物姿势、画面构图、场景结构、人物五官样貌，难以严格按照小说剧情指定画面结构生成配图，可控性极差。

核心详细技术点

（1）双分支模型结构设计

在原有扩散模型主干之外，新增独立控制条件分支，主干负责画面内容生成，分支负责精准约束画面形态，两大分支融合输出，不破坏原有生成能力。

（2）多类型视觉条件精准控制

支持五大核心叙事场景控制：人体姿态控制、场景线稿构图控制、空间深度透视控制、人物 IP 形象固定控制、场景布局结构控制，全方位约束画面形态。

（3）轻量化嵌入部署

无需对基础文生图大模型进行重新训练，仅接入轻量控制模块即可快速实现功能落地，开发难度低、适配课程项目开发节奏。

（4）多条件联合协同调控

可同时叠加人物形象、动作姿态、场景布局多重约束，完美满足小说剧情里固定人物做出指定动作、身处指定场景的配图需求。

（5）低算力适配优化

优化控制分支推理速度，降低图像生成硬件资源消耗，适合前端网页端轻量化调用实现。

学习收获与项目应用

掌握可控文生图的主流实现方式，是本项目文生图模块核心落地技术。项目中借助 ControlNet 固定小说主角形象、约束人物动作与场景构图，让生成插画高度贴合文字剧情，提升整体项目完成度。

5. 《Visualizing Narratives: A Survey of Story Visualization》

发表信息：2024 ACM CSUR 顶级综述论文，故事可视化领域全局综述

研究背景：故事可视化是多模态叙事领域重要分支，领域内技术路线繁多、实现方案杂乱，该论文系统性梳理全领域发展历程、技术流派、现存痛点与未来发展方向。

核心详细技术点

（1）领域技术发展脉络梳理

梳理三大发展阶段：早期 GAN 序列故事图像生成阶段、图文配对检索叙事阶段、当下 LLM + 扩散模型融合叙事可视化阶段，清晰明确项目所处技术阶段。

（2）故事可视化三大核心行业痛点总结

精准归纳领域共性难题：文本与图像语义精准对齐难题、连续叙事画面一致性难题、长篇多章节叙事逻辑可视化难题，完全贴合本项目开发痛点。

（3）主流技术方案横向对比

对比纯文本生图、检索式配图、大模型引导生图、可控约束生图四大方案的优缺点、开发难度、生成效果、适用场景，为项目技术选型提供理论依据。

（4）多模态叙事系统架构规范

定义完整故事可视化标准系统架构：文本输入层、文本解析处理层、图像生成约束层、序列画面统一优化层、结果输出层，可直接套用为本项目整体模块架构。

（5）落地应用场景划分

划分小说插画、动漫分镜、剧本配图、短视频叙事画面等应用场景，明确本项目属于长篇网络小说章节配图细分赛道。

学习收获与项目应用

从宏观层面理清整个项目的架构定位、技术选型依据与行业现存问题，让项目开发具备完整理论支撑。同时参考综述给出的标准分层架构，规范本人负责的文生图模块层级结构，让整体系统设计更加合理规范。

(三)文生音

1. 《Simple and Controllable Music Generation》

发表信息：2023 年 Meta AI 发表于 NIPS，MusicGen 模型官方原始论文，文生音领域的工业级落地标杆工作。

文生音领域核心难点：音乐需要全频采样，序列长度更长，建模难度更高；音乐包含多乐器和声、旋律结构，人类听众对不和谐、旋律错误的容忍度极低；创作者需要多维度可控性，而非仅能生成随机音乐。

此前工作的不足：采用级联多模型，导致计算成本高，误差会逐级积累；单一条件控制，无法满足创作者对风格、旋律等多维度的控制需求；生成质量不足，容易出现不和谐、旋律错误等问题。

核心技术点：

- (1) 采用 EnCodec 模型作为音频分词器，基于残差向量量化（RVQ）实现音频的离散化表示。
- (2) 提出通用的 codebook 交错框架，支持多种分解模式，本模型采用了延迟模式。
- (3) 采用编码器 - 解码器 Transformer 结构，把自然语言描述编码为条件张量，输入 Transformer 解码器。
- (4) 使用无监督的条件旋律控制方案，先通过源分离模型去掉参考音频中的鼓和贝斯，提取剩余部分的色度图，对每个时间步取能量最大的频段作为条件。
- (5) 在模型架构层面，输入是 codebook 嵌入加上正弦位置编码，输入包含因果自注意力层、交叉注意力层、前馈网络的 Transformer 解码器，最后通过码本专属的线性层预测每个码本的下一个 token。

2. 《AUDIOGEN: TEXTUALLY GUIDED AUDIO GENERATION》

发表信息：2023 年 Meta AI 发表于 ICLR

核心技术点：由于两篇论文都出自 Meta AI 团队，在实现技术上有一脉相承的延续性，主要分析二者有区别的地方。

- (1) AudioGen 使用更低的采样率，并采用单代码本的 VQ 架构，区别于 MusicGen 使用带 4 个量化器的 RVQ。
- (2) AudioGen 采用简单的多流 Transformer 并行处理，MusicGen 只用一个自回归 Transformer 解决多条 RVQ 流的预测。
- (3) 提出将不同的音频采样和文本标注在训练时动态混合的技术，解决声音重叠的问题。

3.AudioCraft

简介：2023 年 Meta AI 开源音频生成工具库，集成 MusicGen、AudioGen、EnCodec 三大核心模型，是工业界广泛应用的文生音开源工具。

4.其他的文生音模型

AudioLDM，能够高质量地生成音频。

ACE-Step，开源的多语言人声演唱模型。

以及其他用于生成音乐的模型，如 suno、FluxMusic 等，以及海绵音乐、网易天音等音乐创作平台，总的来说，目前生成的音乐效果最好的仍然是 suno v5.5 的模型。

二、项目进度

文生文小说生成部分已完成，用户输入故事基本设定后，可以结构化生成小说正文文本。



AudioCraft Plaus 本地部署，这里报错是因为爆显存了

AudioCraft Plus - v2.0.1

An All-in-One AudioCraft WebUI

Thanks to: facebookresearch, Camenduru, rkfg, oobabooga, AlexHK and GranddaddyShmax

MusicGen AudioGen Audio Info Changelog About

AudioGen

Generation Audio Customization Settings

Structure Prompts

☐ Enable

Global Prompt

playground

Prompts:

2

Input Text

baseball hit

Repeat

1

Time

00:00 - 00:10

Input Text

crowded cheer

Repeat

1

Time

00:11 - 00:25

Calculate Timings

Duration

25

Overlap

2

Output Wiki

Error

Error

Send to Input Audio

Error

Error