

二、文生图

优化大模型提取角色特征的逻辑，增强对角色一致性的控制。并完善章节配图的自动提取提示词功能，使得提示词按照正规的文生图结构生成，包括场景、角色、事件、镜头、光照、质感、氛围等关键词。





三、文生音

1. 《Stable Audio 3》

简介：Stability AI 在 5 月 20 日推出的最新的 AI 音乐生成模型，包括 small、medium、large 三个规模的模型，其中 small 和 medium 的权重均开源，并且适用于在笔记本电脑上运行。

核心亮点：

- (1) 以前的扩散模型生成音频时，总是固定长度，比如每次生成 30 秒。但你如果只需要 5 秒的提示音，它也得先算 30 秒再剪掉，浪费大量算力。论文提出变长生成，让模型按需求时长生成，计算成本与时长成正比。并在推理时用了乒乓采样，进一步加速。
- (2) 引入 inpainting，即音频修补。可以用文字提示编辑某个段落，或者延续一段录音。比如给一段钢琴伴奏，提示‘加入小提琴’，模型就在指定区域生成小提琴，而且不需要额外训练数据。

2. 《IndexTTS2: A Breakthrough in Emotionally Expressive and Duration-Controlled Auto-Regressive Zero-Shot Text-to-Speech》

简介：由 bilibili 开源的语音生成模型，支持语音时长控制与情感控制。

核心亮点：

- (1) 提出同时支持精确时长控制和自然时长生成的自回归零样本模型。IndexTTS2 引入了一个可选的时长 token，让模型在生成语音前先预测这句话要持续多长时间。比如输入“大家好”并指定 0.8 秒，模型就会严格按照这个时长生成。而且

能在不指定时长时，自然地生成出符合上下文节奏的语音，就像人说话一样有快有慢。

(2)情感 - 音色解耦。把情感信息从音色中分离出来，通过一个情感编码器独立控制。

(3)三阶段训练策略。第一阶段只在大量无情感数据上训练基础生成能力，第二阶段加入少量情感数据微调情感模块，第三阶段联合训练全部模块。

(4)GPT 隐层增强。利用预训练语言模型（像 GPT）的中间层表示来辅助语音生成。

(5)自然语言情感控制。允许直接用文字描述情感，而不需要用离散标签或是参考音频。

3. 目前进度

模型选择

音频生成模型

MusicGen (Meta) — 快速、轻量

MusicGen (Meta) — 快速、轻量

Stable Audio 3 (Stability AI) — 高质量

模型变体

musicgen-small (300M)

接入 Stable Audio 3，使用同样的思路，首次生成时，模型将下载于本机上。

角色音色管理

语音合成

章节批量配音

N

角色音色管理

创建角色、上传参考音频，为小说角色定制专属声音

创建角色

角色名称

输入角色名称，如：张三

角色描述

简要描述角色性格特点

创建角色

角色列表

暂无角色，请先创建

检测中...

搭建 TTS 配音界面，允许用户自定义角色画像，为小说文本内容进行配音。情感分析功能参考了 B 站 up 主阿也 nico 开发的 emotionTTS 的实现思路，在 TTS 与前面页面之间增加一层大模型的情感分析，结合情节以及人物设定来调节情感参数。由于 IndexTTS2 项目部署非常庞大，不容易集成，目前前端页面会检测 IndexTTS 的默认端口 9800 是否启动，需要额外本地部署才能进行调用。