



社交网络技术与应用

第一章第一节：课程介绍和社交网络概述

“Knowledge is of two kinds: we know a subject ourselves,
or we know where we can find information upon it.”

-- Samuel Johnson (1709-1784)

大纲

□ 课程安排

□ 社交网络概述

- ❖ 什么是社交媒体
- ❖ 当今主流社交媒体平台有哪些
- ❖ 什么是社交媒体分析
- ❖ 社交媒体分析面临的挑战是什么

主讲教师

□ 王晓黎

❖ Email: xlwang@xmu.edu.cn

❖ QQ: 297389281

❖ Office: 西部片区1号楼302

□ 助教：罗琦媛、周祺浩

课程时间安排

□周三3、4节：10:10am–11:50am

❖地点：学武楼（1号楼）C305

□单周周五3、4节：10:10am–11:50am

❖地点：西部片区（4号楼）208

❖注意：实验课可自带笔记本

线上答疑QQ群

QQ Group:



厦门大学数字教学中心平台

课程链接地址:

<https://lnt.xmu.edu.cn/course/92507/content/>

课程目标

- 通过这门课程的学习，学生将对社交媒体的技术、应用以及未来发展趋势有更深刻的了解
- 通过学习社交网络技术的应用实例，激发学生未来的创业与研究兴趣
- 配合一些上机实验，使学生学会应用开源的**Python**框架完成社交媒体分析大模型的训练、微调与推理，并掌握多模态数据处理和分析方法

课程要求

□ 基础支撑课程

❖ 无

□ 参考资料

- ❖ **Sebastian Raschka. Build a large language model (from scratch), Manning, 2024.**
- ❖ **Zafarani, Reza, Mohammad Ali Abbasi, and Huan Liu. Social media mining: an introduction. Cambridge University Press, 2014.**
- ❖ **Jiawei Han, Micheline Kamber, and Jian Pei. Data Mining: Concepts and Techniques, Second Edition. Morgan Kaufmann, 2006.**
- ❖ **其他Google、百度公开资源**

课程内容

- 社交网络介绍-了解社交网络的发展现状和社交媒体分析的主要挑战
- 社交网络内容处理-数据爬取、清洗、处理与查询，如何使用开源模型爬取和处理社交媒体数据
- 社交媒体分析与应用-如何使用开源模型分析社交媒体数据

教学大纲（1）

章节	主要内容	学时安排
第一章 社交网络介绍	课程整体概述；介绍社交网络的背景与当今发展趋势，包括国外的Facebook、Twitter以及国内的微信、微博等热门社交网络系统的各种应用实例；介绍Python开源框架和开发环境，动手实践使用Python开源框架快速建立一个社交媒体分析平台	2+2
第二章 数据处理	介绍社交媒体数据处理核心技术，包括数据收集、数据预处理和数据融合等，使用Python开源框架进行相关实验	4+2
第三章 数据建模	介绍社交媒体数据建模相关技术，包括基本数据建模方法、社交图、知识图谱等，并了解数据表示学习模型	6+2

教学大纲（2）

章节	主要内容	学时安排
第四章 数据检索与分析	介绍当今热门的社交媒体检索与分析相关技术：文本索引、文本检索、文本挖掘和情感分析、大语言模型；介绍如何使用Python开源代码分析社交媒体数据	8+6
第五章 社交媒体应用	介绍事件检测与热点追踪、问答系统、大预言模型的垂直领域应用等；介绍如何使用Python开源框架进行相关实验	8+4
第六章 课程大作业展示	学生大作业展示	2

课程考核

□ 课堂问题讨论（10%）

❖ 要求学生积极参与每节课堂上一些相关问题的讨论

□ 上机实验报告（50%）

□ 课程大作业（40%）

课程考核：实验报告

- 分值占期末总成绩的**50%**
- 本学期有7次两个学时的实验课，提交的实验报告有4次将作为课后作业，另外3次实验报告需在课上提交
- 每次课后作业分值占期末总成绩的**10%**
- 3次上机实验占期末总成绩的**10%**
- **注意：有些报告可能以组为单位提交，实验分组与“课程大作业”一致**

课程考核：课程大作业

- 分值占期末总成绩的**40%**
- 课程大作业：社交媒体数据分析模型
 - ❖ 具体内容和分值会在第三周给出
- 本学期有7次两个学时的实验课，学生会逐步完成课程大作业的每个模块，另有一个模块需要学生自主开发，最后整合源代码、演示系统并提交大作业报告
- 组队：**4人一组**

课程纪律

□ 课堂考勤

- ❖ 助教会每节课进行签到
- ❖ 课堂上会有开放性问题的讨论

□ 作业提交

- ❖ 每次课后作业请按时提交，迟交将按照规定扣分
- ❖ 每次上机实验需按照要求时间提交报告
- ❖ 4次课后作业+3次上机实验报告

大纲

□ 课程安排

□ 社交网络概述

- ❖ 什么是社交媒体
- ❖ 当今主流社交媒体平台有哪些
- ❖ 什么是社交媒体分析
- ❖ 社交媒体分析面临的挑战是什么

什么是社交媒体(Social Media)？

- 百度百科：社交媒体指互联网上基于用户关系的内容生产与交换平台
- 社交媒体是人们用来分享意见、见解、经验和观点的工具和平台，现阶段主要包括社交网站、微博、微信、博客、论坛、播客等等



**[http://edu.cnr.cn/list/20150922/
W020150922360259944631.jpg](http://edu.cnr.cn/list/20150922/W020150922360259944631.jpg)**

社交媒体的主要特点

- 每个人都可以是内容发布者
- 丰富的用户互动行为
- 用户可以自发地发布、传播、加工、再发布内容
- 集体智慧
- 长尾（**long tail**）理论

社交媒体vs传统媒体



Broadcast Media
Filter->Publish



Social Media
Publish->Filter

什么是集体智慧？

自然界



人类




互联网



<https://wenku.baidu.com/view/f2ca432f773231126edb6f1aff00bed5b9f3737a.html>

集体智慧

- 维基百科定义：集体智慧是一种共享的或者群体的智慧，它是从许多个体的合作与竞争中涌现出来的，出现在一致性决策之中
- 通俗来讲，集体智慧是由组成群体的个人贡献出自己的知识、技能、经验，通过一些共享机制，产生优于个人的智慧



集体智慧特征

□多样性

- ❖ 群体里的每个人都有一些独占信息

□独立性

- ❖ 群体内的成员不会因为其他人的意见而改变自己的意见

□民主性

- ❖ 成员的决策行为不会受到外在压力的强迫，而整个群体的决策则是由所有成员的决策汇聚而成

集体智慧 vs 群体极化

- 只有在独立思考时，在群体具有多元性和异质性且不预设任何“正确”的决定或结果时，集体智慧才能发生
 - ❖ 只有由不同年龄、背景，具有不同兴趣、专长的大型群体产生不同或相悖的观点时，才会有集体智慧
- 群体极化是没有多元意见或不同声音的，从本质上就不欢迎独立思考

社交媒体中的集体智慧

□ 示例


【📢 谁家的孩子！快来领！】今天，成都光华派出所“小鲜肉”师弟@粥泡饭Z 值班坐台，一8岁冉姓小盆友据称在清水河大桥附近与家人走散。小盆友不给帅哥面子，无论蜀黍如何卖萌，熊孩子都不说父母姓名，地址、电话也说不清楚。如能帮忙联系其父母，请与帆Sir联系：028-87370431。#还有，蜀黍不约！#



2月6日 12:08 来自 微博 weibo.com

收藏

转发 10771



<https://baijiahao.baidu.com/s?id=165781316170669&wfr=spider&for=pc>



社交媒体中的群体极化

□ 示例

微博:因上传传播涉冬奥侵权内容,500余个账号被禁言

2022年2月9日 站方再次提示,中央广播电视总台拥有北京2022年冬奥会在大陆地区(含澳门)独家全媒体权利及分授权权利。如未经权利人授权,在**微博**平台上以不符合法律规定的...

 澎湃在线  百度快照

新浪**微博**:已处理冬奥侵权内容四千余条 500余个账号被禁言...

2022年2月9日 对上传传播涉冬奥侵权内容的用户进行版权教育,对违规用户采取禁言等管理措施,累计对500余个账号采取禁言10天至30天的处置。**微博**站方提示,中央广播电视总台拥有...

 腾讯网  百度快照

讽刺攻击冬奥运动员,850个**微博**账号被禁言



2022年2月9日 根据《**微博**社区公约》等相关规定,站方主动对涉**冬奥会**相关内容进行了排查与治理,共清理违规**微博**41473条,对@怕怕菊@Real银耳连梓更@我是你的背带裤等850个账号,视程度采取禁言30天...

 中国长安网  百度快照

<https://www.baidu.com/>


开放性讨论问题1

□ 你认为社交媒体如何避免“群体极化”？

什么是长尾理论？

- 维基百科定义：由《连线》杂志主编 **Chris Anderson** 在2004年十月的“长尾”一文中最早提出，用来描述诸如**Amazon**和**Netflix**之类网站的商业和经济模式
- 简单说，那些原来不受到重视的销量小、种类多的产品或服务由于总量巨大，累积起来的总收益超过主流产品的现象

❖ 薄利多销



社交媒体中的长尾理论

□ 示例：Amazon

- ❖ 一家大型书店通常可摆放**10万**本书，但亚马逊网络书店的图书销售额中，有一半来自排名**10万**以后的书籍





图3 亚马逊销售排行第10万名以后图书的销售比例

资料来源: Brynjolfsson, Hu, and Smith, "Consumer Surplus in the Digital Economy".

<http://www.wenxue100.com/baokan/75566.shtml>


社交媒体主要发展进程

社交媒体高速演变，呈现内容共生与多元形式融合的新格局。




社交媒体主要发展进程

Social Media Timeline



社交媒体主要发展进程



什么是社交媒体分析？

□ 维基百科：

Social Media Analytics is the process of gathering data from stakeholder conversations on digital media and processing into structured insights leading to more information driven business decisions and increased customer centrality for brands and businesses.^[1]

Social media analytics can also be referred as social media listening, social media monitoring or social media intelligence. It is a term covered by [Social Analytics](#).

[Digital media](#) sources for social media analytics include social media channels, blogs, forums, image sharing sites, video sharing sites, aggregators, classifieds, complaints, Q&A, reviews, Wikipedia and others.

Social media analytics is an industry agnostic practice and is commonly used in different approaches on business decisions, marketing, customer service, reputation management, sales and others.^[2] There is an array of tools that offers the social media analysis, varying from the level of business requirement. Logic behind algorithms that are designed for these tools is selection, [Data pre-processing](#), transformation, mining and hidden pattern evaluation.

应用示例：邮件

□ 邮箱基本功能：用户邮件列表，允许用户手动对邮件进行标记和分类


□ 社交媒体分析的应用

❖ 辅助功能：帮助用户自动对邮件进行分类
如，垃圾邮件，广告邮件等

❖ 商业价值：挖掘用户个人偏好和兴趣，发送用户真正需要的广告
如，Gmail广告

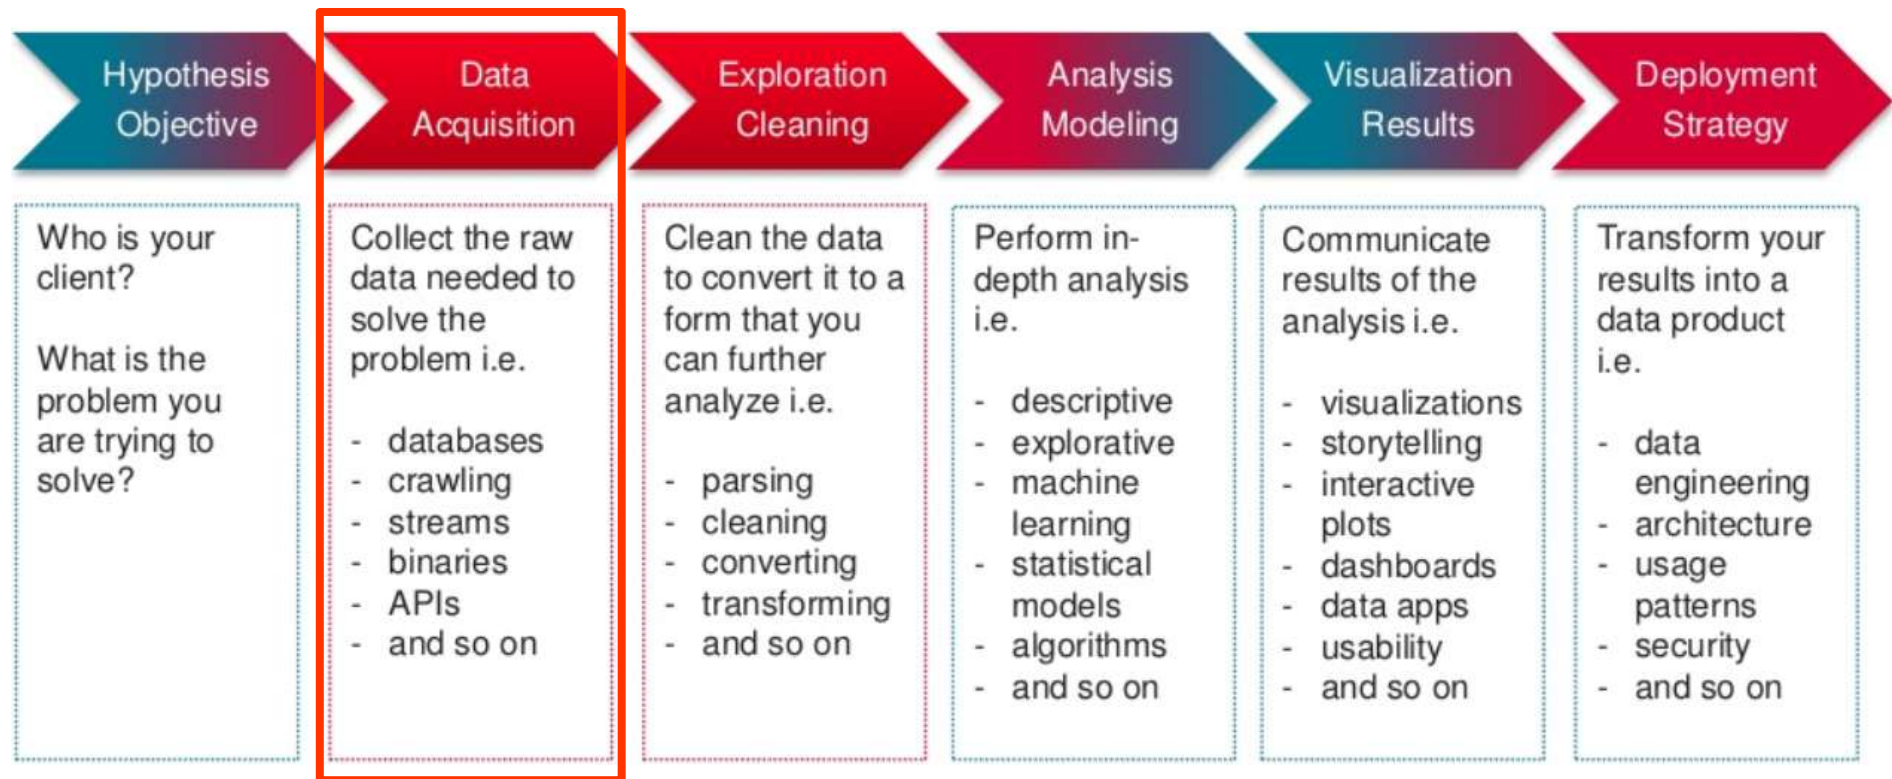
如何进行社交媒体分析？

□ 数据分析基本步骤




如何进行社交媒体分析？

□ 数据分析基本步骤



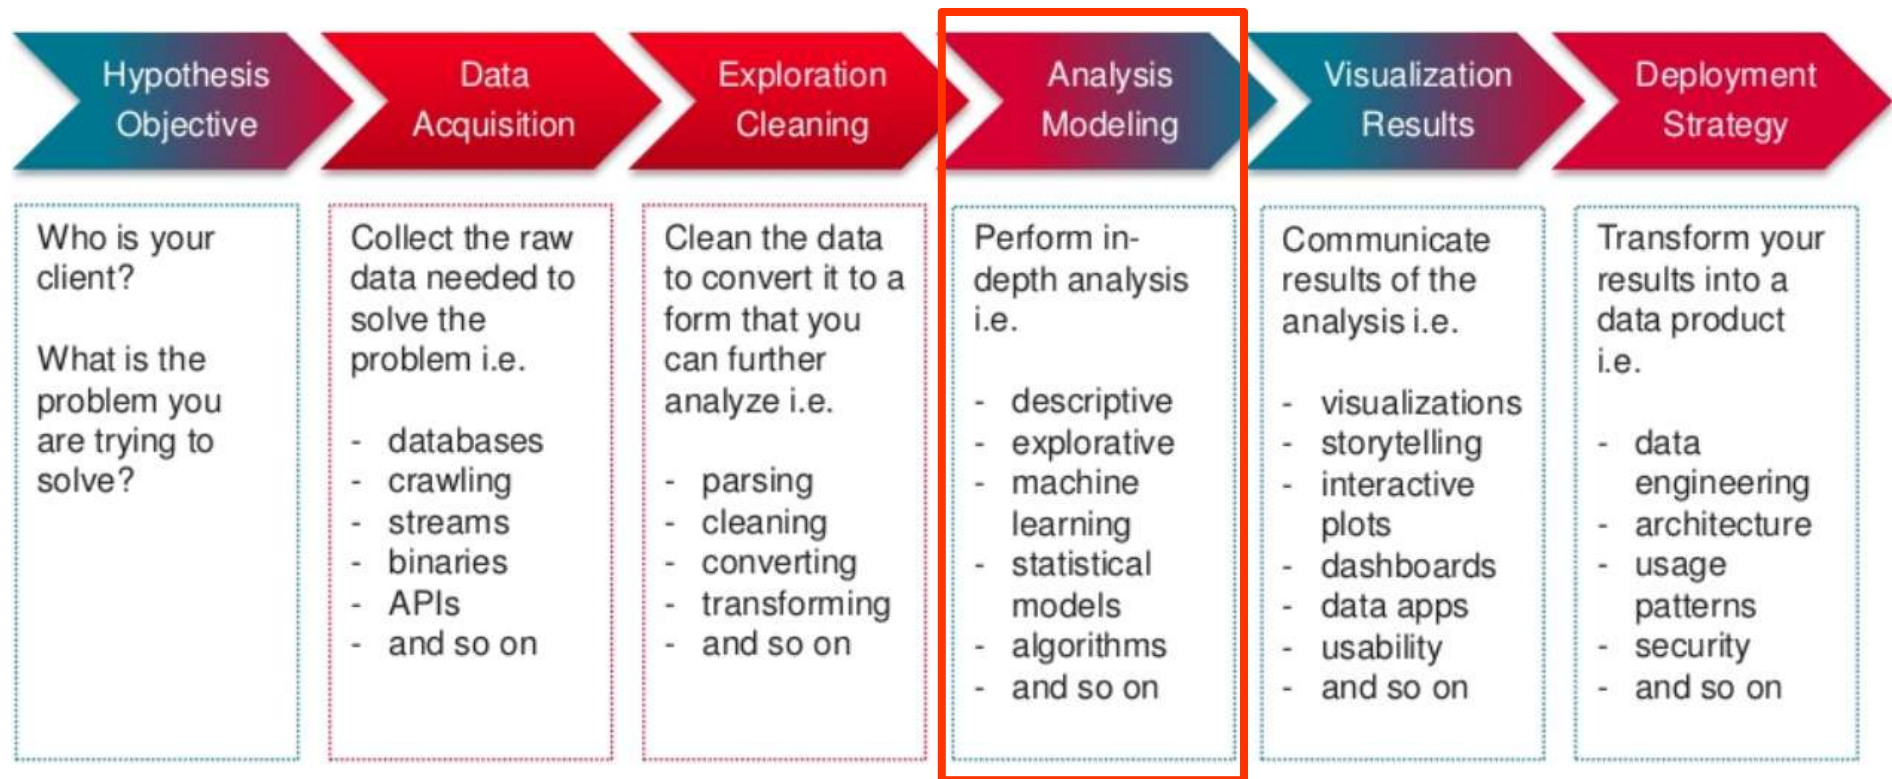
如何进行社交媒体分析？

□ 数据分析基本步骤



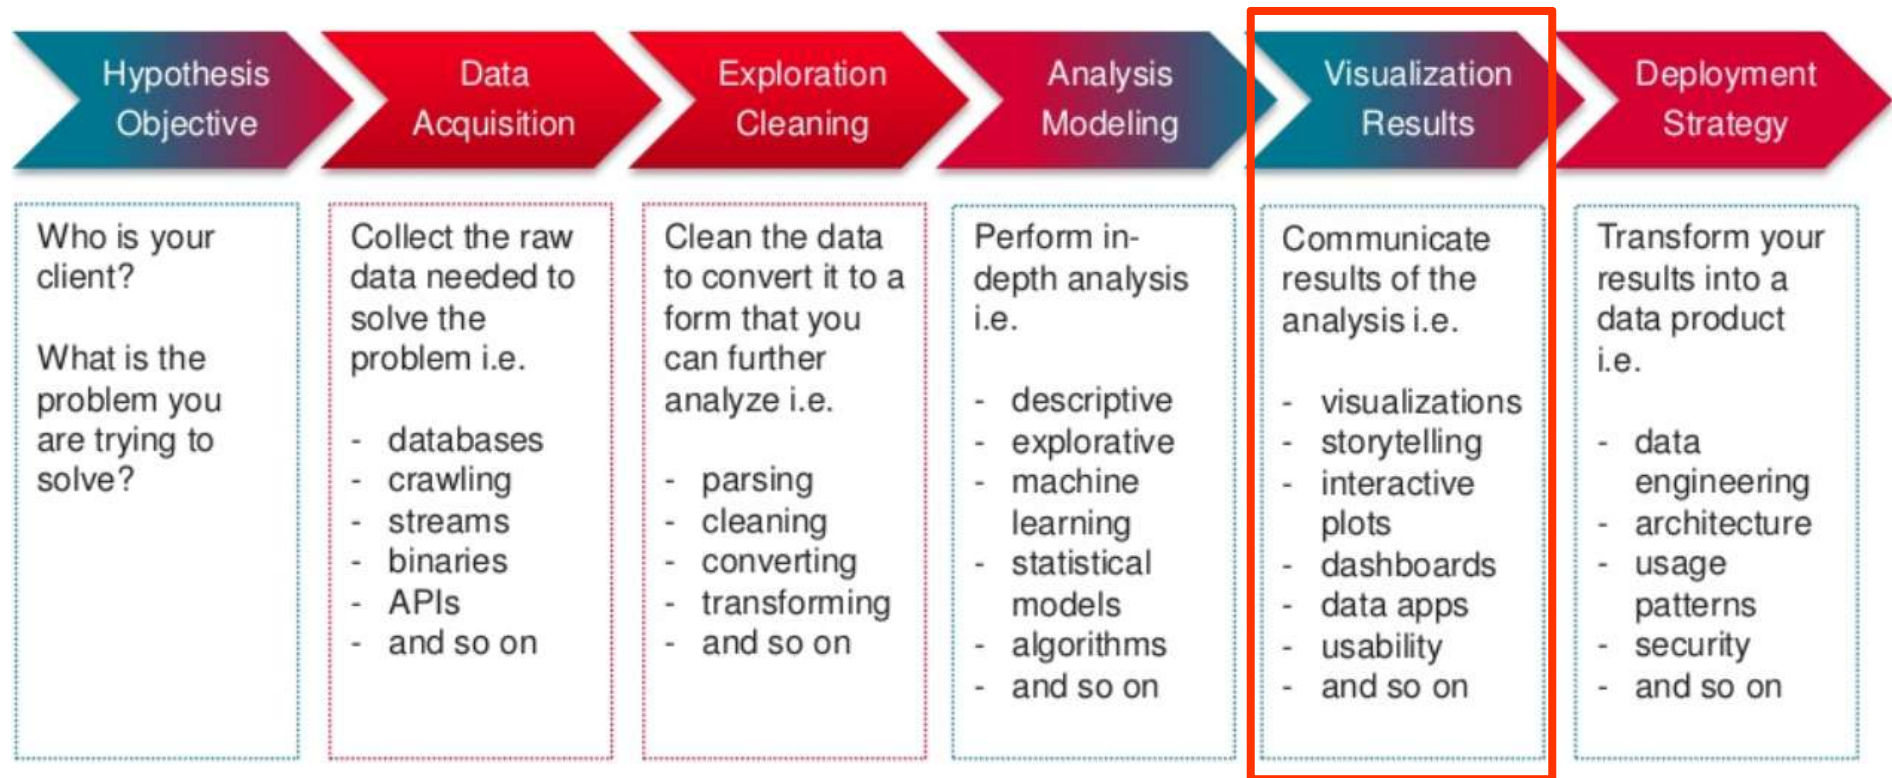
如何进行社交媒体分析？

□ 数据分析基本步骤



如何进行社交媒体分析？

□ 数据分析基本步骤



案例：丁香园新型冠状病毒疫情实时动态

□ 问题背景

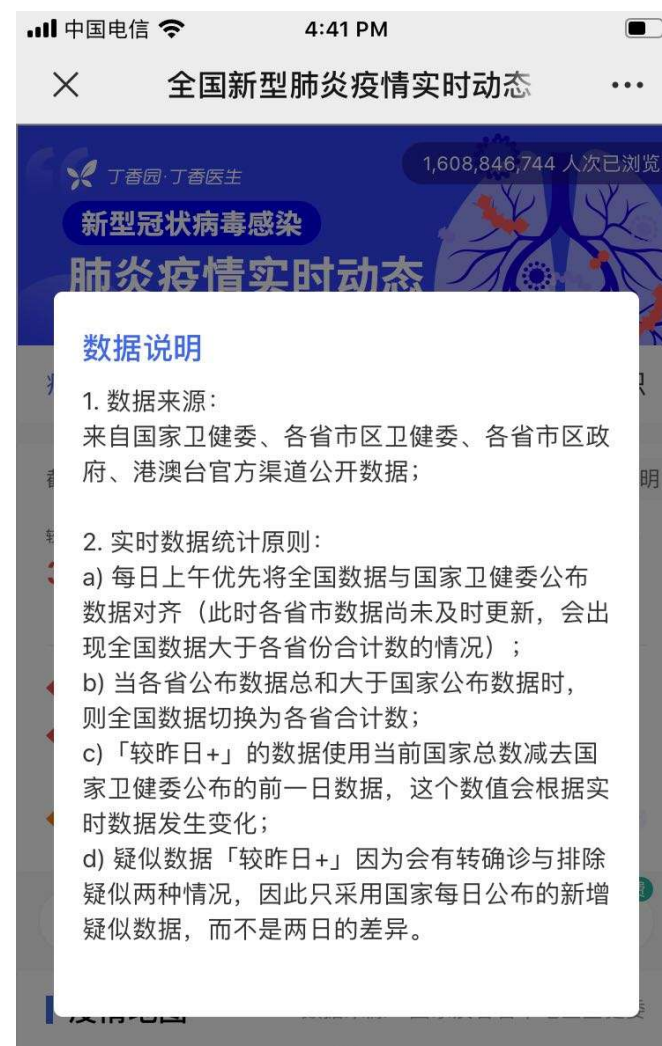
❖ 对全国新型冠状病毒疫情动态进行实时分析

□ 数据采集

❖ 数据来源：国家及各省市地区卫健委

□ 数据处理

❖ 实时数据预处理与对齐




案例：丁香园新型冠状病毒疫情实时动态

□ 数据建模与分析

- ❖ 对全国新型冠状病毒疫情各省市数据进行实时统计分析

□ 数据可视化

- ❖ 疫情地图
- ❖ 趋势图



案例讨论： 百度PPT文档助手示例

The image displays the Baidu PPT Document Assistant interface, which is used for generating PPTs from documents. The interface is divided into two main sections: a document upload and generation area on the left, and a PPT preview area on the right.

Left Panel (Document Upload and Generation):

- Top Bar:** Includes a back arrow, tabs for "创作" (Create) and "探索" (Explore), and a "+" icon.
- Section Header:** "选择文档生成PPT" (Select document to generate PPT).
- Instruction:** "请根据下面这篇文档内容生成PPT" (Please generate PPT based on the content of the following document).
- Document List:** Shows a document titled "3_新建 microsoft word 文档" (3_New Microsoft Word Document) with a size of 13.45kb and a status of "上传成功" (Upload successful).
- PPT Outline Writing:** A section titled "PPT大纲写作中" (PPT Outline Writing in Progress) showing the outline for "3_新建 microsoft word 文档".
- Outline Content:**
 - 3_新建 microsoft word 文档**
 - 引言** (Introduction)
 - NLP和AI的关系
 - NLP的重要性和应用
 - 文本生成任务的趋势** (Trends of Text Generation Tasks)
 - 文本到文本的生成
 - 数据到文本的生成
- Status:** "PPT大纲正在生成中" (PPT Outline is being generated).
- Buttons:** "停止" (Stop) and "发送" (Send).

Right Panel (PPT Preview):

- Section Header:** "3_新建microsoftword文档".
- Preview Grid:** A grid of 12 slides showing the generated PPT content. The slides include:
 - Slide 1:** Title slide "3_新建microsoftword文档".
 - Slide 2:** Table of contents "目录".
 - Slide 3:** Section "01 引言".
 - Slide 4:** Section "02 文本生成任务的趋势".
 - Slide 5:** Section "03 文本生成任务的定义".
 - Slide 6:** Section "04 Text-to-Table问题的定义".
 - Slide 7:** Section "05 BERT在Text-to-Table问题上的应用".
 - Slide 8:** Section "06 总结".
 - Slide 9:** Section "07 参考文献".
 - Slide 10:** Section "08 附录".
 - Slide 11:** Section "09 致谢".
 - Slide 12:** Section "10 其他".
- Buttons:** "发送" (Send) and "编辑" (Edit).

案例讨论：DeepSeek的使用

下午3:05 | 0.4K/s

二 接下来我将向你提出一个...

接下来我将向你提出一个问题，需要你简短的回答，因为我需要使用手机截图，将提问和回答保存在一张截图中

好的，请提问，我会简短回答。

< 4/4 >

什么是多模态数据

多模态数据指来自不同来源或形式的数据，如文本、图像、音频、视频等，结合使用以提供更全面的信息。

给 DeepSeek 发送消息

深度思考 (R1) 联网搜索

下午3:10 | 0.2K/s

二 什么是社交网络?

什么是社交网络?

已深度思考 (用时 24 秒)

嗯，用户问什么是社交网络，我需要先理清这个问题的核心。社交网络这个词现在很常见，但可能不同人理解不同。首先，我应该从基本定义入手，解释社交网络的概念。然后可能需要说明它的主要功能，比如连接用户、分享信息、互动交流这些方面。接着，可能得提到不同的类型，比如像 Facebook、微信这样的综合平台，或者像 LinkedIn 这样的职业社交，还有 Instagram 这样的图片分享。

然后，用户可能还想知道社交网络的结构，比如用户如何建立个人资料，添加好友，形成关系网。这部分需要简明扼要，避免太技术化。另外，社交网络的影响也是重要的点，比如对个人生活的影响，社会的影响，还有商业营销方面的应用。不过要注意平衡正反两面，比如提到信息过载、隐私问题这些负面因素。

可能还需要考虑用户的背景。如果用户是普通用户，可能更关注日常使用的方面；如果是学生，可能需要更学术一些的定义。但问题本身比较通俗易懂比较

给 DeepSeek 发送消息

深度思考 (R1) 联网搜索

下午3:10 | 5.4K/s

二 什么是社交网络?

还要注意回答的长度，用户可能希望一个全面但不过于冗长的解释。所以每个部分点到为止，不展开过多细节。检查是否有重复的内容，确保每一段都有新的信息。最后，用简短的总结来收尾，强调社交网络的多方面影响和重要性。

社交网络 (Social Network) 是指通过互联网平台将用户连接起来，允许他们创建个人资料、分享信息、互动交流，并构建线上社交关系的虚拟社区。以下是其核心要点：

1. 基本构成

- 用户节点：每个用户作为网络中的个体，通过个人资料（如头像、简介）展示身份。
- 关系链：用户通过“关注”“好友”等功能建立连接，形成好友、粉丝、社群等关系网络。
- 内容交互：用户发布文字、图片、视频等内容，通过点赞、评论、转发等方式互动。

给 DeepSeek 发送消息

深度思考 (R1) 联网搜索

面临的挑战（1）

□ 如何处理多模态数据

- ❖ 社交媒体数据一般包含图像、音频、视频等其他模态的数据



□ 实时位置信息分析

- ❖ 生活中到处都有传感器
- ❖ 多源信息：位置轨迹、**POI**和音频等
- ❖ 用于位置预测和移动分析

面临的挑战（2）

□ 社交网络系统极易变成“垃圾场”

❖ 25%的链接都是指向垃圾消息

无关广告

虚假消息

诈骗页面

□ 传统的数据清洗方法用处不大

□ 社交网络系统正在面临更大的挑战, Sybils



面临的挑战（3）

□大语言模型

❖ 检测与过滤：识别虚假或恶意内容

❖ 幻觉：

生成的内容看起来毫无意义或者与提供的源内容不符

产生原因：错误信息和偏见、知识边界、复杂场景、知识捷径、知识召回失败

可能生成不真实或误导性信息，反而加剧垃圾信息扩散

三 介绍一下牛顿晚年著作《天体之光》

+ 新对话

介绍一下牛顿晚年著作《天体之光》

牛顿晚年的著作**《天体之光》**是一部关于神学和宗教的论著，而非科学著作。

在牛顿的学术生涯中，他不仅在自然科学领域取得了巨大成就，还对宗教和神学表现出了浓厚的兴趣。牛顿的宗教信仰深受其时代背景和个人经历的影响，他试图通过科学研究来证明上帝的存在和圣经的真理性。据历史记载，牛顿花费了大量时间研究圣经，并尝试解开其中的奥秘。

《天体之光》是牛顿晚年转向宗教研究的代表作之一，它体现了牛顿试图将科学与宗教相结合的思想。尽管这部著作在科学界的影响力不如他的《自然哲学的数学原理》等作品，但它对于理解牛顿的世界观和他对宇宙本质的思考具有重要意义。

总的来说，牛顿的《天体之光》不仅是对他个人信仰的阐述，也是对当时科学与宗教关系的一种探索。



注意

□3月15日23: 59之前

❖ 完成实验和大作业分组

4人一组

请在QQ群共享在线文档“学生分组.excel”中编辑并填写相关信息

大作业的报告顺序以excel文件中的顺序为依据，如果需要调整顺序，请和别组进行协商

如果在截至时间之前没有完成分组，将由助教随机进行分组并随即决定报告顺序

□下节课开始将采用中/英文双语课件

参考资料

- **GWJ: 2022社交媒体趋势报告**
- **腾讯媒体研究院: 2023年全球社交媒体趋势报告**
- **Werner Geyser: 2024年及以后的社交媒体趋势**



谢谢！
下一节内容：数据爬取

