

廈門大學



信息学院

《社交网络技术与应用》

作业三 数据清洗

实验题目 数据清洗

组 员 37220232203780 马鑫

1 实验介绍

在先前的 Lab 2 中，各小组已经选定了特定的医疗子领域并进行了数据爬取。本实验旨在学习工业界标准的数据清洗流水线，通过解读老师提供的基准代码（Baseline），掌握非结构化文本的正则清洗与 LLM 自动化评估技术，并将该技术迁移应用到各小组在 Lab 2 爬取的自有数据集中，最终构建出高质量的领域微调数据集。

实验目的

- 理解并跑通基准清洗与评估代码，掌握其底层逻辑。
- 具备举一反三的能力，针对不同的脏数据定制开发专属的正则表达式。
- 掌握 Prompt Engineering，能够针对特定医疗子领域的质量要求，设计 LLM-as-a-Judge 的评估维度。

2 示例代码解析与跑通 (20%)

目的：理解老师提供的基线代码逻辑。请在本部分展示你们成功运行老师提供的 `clean.py` 和 `filter_llm.py` 处理 `qa.txt` 的结果，并用自己的话简略回答以下问题：

技术选型对比：我们在第一步使用了正则表达式进行清洗，而没有直接让大模型去清洗脏文本，请分析这种“规则 + 算法”组合方案在实际工程中的优势是什么？

答：（1）节省算力，不需要耗费大模型的 token；（2）结果可控，输出结果都能在期望范围之类，相较于大模型可能会出现幻觉更加稳定。（3）使用 CPU 资源，速度更快，可处理的文本量更大。（4）本地处理，更有利于保护数据隐私。

数据清洗决策：在 `clean.py` 中，如果患者的提问（user content）少于 3 个字，代码会直接跳过该条消息。你认为在医疗问诊场景下，这么做的合理性是什么？

答：降低噪声的污染，在实际爬取的数据中可能会含有部分如“嗯”，“哦”之类的语气词和“好的”等简单的回复等无效信息，或者会错误爬取到部分 HTML 的文本结构或 UI 组件等。

大模型裁判反思：打开你生成的 `low_quality.json`，随机挑选一条数据，阅读大模型给出的低分理由（reason）。你认为大模型的评判客观吗？在完全自动化的质量评估中，可能存在哪些隐患？

答：大模型的评判完全客观。大模型知识库中缺乏诊疗规范和复杂医学问题，可能会导致判断错误；对上下文与多轮对话的关联能力不足，发生断章取义的现象；同理心属于主观人文维度，使用算法可能会造成粗糙量化。

基线运行结果：

对 `qa.txt` 文档进行了截取，运行结果如下：

运行 `clean.py`:

```
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python\SocialMedia\Lab3_DataEngine> python clean.py
数据清洗完成！共处理出 259 条有效对话记录。
总记录数 347，成功 259，跳过 88。
跳过原因（合计）：{'invalid_format': 88}
```

`clean_dataset.json` 部分内容：

```
{
  "messages": [
    {
      "role": "system",
      "content": "你是一位来自【自贡市第七人民医院 全科 自贡市第七人民医院 儿科】的专业医生，请根据患者的描述提供专业建议。",
    },
    {
      "role": "user",
      "content": "【患者基本信息与诉求】\n流鼻涕\n流黄色粘稠鼻涕一个月左右，有点儿咳嗽，其他一切正常，情况不是很严重",
    },
    {
      "role": "assistant",
      "content": "感谢您的信任，病情资料我已详细阅读。根据您现有的资料，建议：小孩症状符合感冒后鼻炎"
    },
    {
      "role": "user",
      "content": "怎么办好"
    },
    {
      "role": "assistant",
      "content": "建议用小儿头孢克肟颗粒，羟甲唑林喷雾剂喷鼻，孟鲁司特钠片口服"
    },
    {
      "role": "user",
      "content": "要去医院看看吗？但是看他情况也不严重\n\n每天都是流黄色粘稠的鼻涕"
    },
    {
      "role": "assistant",
      "content": "可用我推荐的药看看"
    },
    {
      "role": "user",
      "content": "请问大概吃多久？春节前他咳嗽医生有给他开过头孢克肟颗粒和孟鲁司特钠片了\n\n感觉对他咳嗽没有很大效果"
    },
    {
      "role": "assistant",
      "content": "【诊断与建议】\n病情摘要及初步印象：\n患儿感冒后流黄涕2月初步诊断：鼻炎\n总结建议：\n建议用羟甲唑"
    }
  ],
  "meta": {
    "id": "29257",
    "url": "https://www.haodf.com/doctorteam/flow\_team\_6477245131.htm"
  }
},|
```

运行 filter_llm.py:

[illegible]

```
评估中: 100% | 259/259 [4:39:49<00:00, 64.82s/it]

正在保存结果...

✓ 高质量数据: 14 条
✓ 中等质量数据: 41 条
✓ 低质量数据: 204 条
✓ 全部数据 (含评分) 已保存

=====
筛选完成
=====
高质量 (≥75分): 14 条 (5.4%)
中等 (60-74分): 41 条 (15.8%)
低质量 (<60分): 204 条 (78.8%)
-----
平均分: 46.5
最高分: 85
最低分: 10
=====

全部完成!
```

all_with_scores.json:

```
2      {
3        "messages": [
16      {
17        "role": "user",
18        "content": "怎么办好"
19      },
20      {
21        "role": "assistant",
22        "content": "建议用小儿头孢克肟颗粒，羟甲唑林喷雾剂喷鼻，孟鲁司特钠片口服"
23      },
24      {
25        "role": "user",
26        "content": "要去医院看看吗？但是看他情况也不严重\n\n每天都是流黄色粘稠的鼻涕"
27      },
28      {
29        "role": "assistant",
30        "content": "可用我推荐的药看看"
31      },
32      {
33        "role": "user",
34        "content": "请问大概吃多久？春节前他咳嗽医生有给他开过头孢克肟颗粒和孟鲁司特钠片了\n\n感觉对他咳嗽没有很大效果，也吃了十天左右，现
35      },
36      {
37        "role": "assistant",
38        "content": "【诊断与建议】\n病情摘要及初步印象：\n患儿感冒后流鼻涕2月初步诊断：鼻炎\n总结建议：\n建议用羟甲唑林喷雾剂，布地奈德喷
39      }
40    ],
41    "meta": {
42      "id": "29257",
43      "url": "https://www.haodf.com/doctorteam/flow_team_6477245131.htm"
44    },
45    "qwen_evaluation": {
46      "score": 42,
47      "quality_level": "低质量",
48      "reason": "医生未回应患者关于用药的核心诉求，对持续一月黄脓涕可能提示的鼻窦炎风险识别不足，缺乏具体治疗方案及就医指导，回答过于简略。
49      "dimension_scores": {
50        "accuracy": 55,
51        "advice": 20
52      }
53    },
54    "qwen_score": 42
```

high_quality.json:

```

7      },
8      {
9        "role": "user",
10       "content": "【患者基本信息与诉求】\n怀孕\n末次月经2月17日,\n今天检查孕酮低,\n一周后b超,\n请问应该阴道b超还是腹部b超好?\n哪种b超好\n怀孕情况:\n孕5周\n一周内\n已就诊医院J
11     },
12     {
13       "role": "assistant",
14       "content": "你好,一般阴道超声看的比较清楚,看胎芽,胎心都要比腹部早一些看到"
15     },
16     {
17       "role": "user",
18       "content": "哦,\n2月17日末次月经,\n约的下周3,\n这个日期不知行不,\n到日期了吗?"
19     },
20     {
21       "role": "assistant",
22       "content": "这个需要结合你化验的血HCG值给你判断"
23     },
24     {
25       "role": "user",
26       "content": "今天测HCG4611"
27     },
28     {
29       "role": "assistant",
30       "content": "现在做阴超的话,应该可以确定是宫内孕还是宫外孕,有胎心的话需要等两周左右"
31     },
32   ],
33   "meta": {
34     "id": "29293",
35     "url": "https://www.haodf.com/doctorteam/flow_team_6477245192.htm"
36   },
37   "qwen_evaluation": {
38     "score": 83,
39     "quality_level": "高质量",
40     "reason": "医学知识准确且建议安全,清晰解答了 B 超选择疑问,但未回应孕酮低的焦点,缺乏检查前准备指导及人文关怀,整体简洁有效但有提升空间。",
41     "dimension_scores": {
42       "accuracy": 95,
43       "advice": 80
44     }
45   },
46   "qwen_score": 83

```

low_quality.json:

```

2    {
3      "messages": [
16     {
17       "role": "user",
18       "content": "怎么办好"
19     },
20     {
21       "role": "assistant",
22       "content": "建议用小儿头孢克肟颗粒,羟甲唑林喷雾剂喷鼻,孟鲁司特钠片口服"
23     },
24     {
25       "role": "user",
26       "content": "要去医院看看吗? 但是看他情况也不严重\n\n每天都是流黄色粘稠的鼻涕"
27     },
28     {
29       "role": "assistant",
30       "content": "可用我推荐的药看看"
31     },
32     {
33       "role": "user",
34       "content": "请问大概吃多久? 春节前他咳嗽医生有给他开过头孢克肟颗粒和孟鲁司特钠片了\n\n感觉对他咳嗽没有很大效果,也吃了十天左右,现在还是有点咳嗽的\n\n每天都有咳几下"
35     },
36     {
37       "role": "assistant",
38       "content": "【诊断与建议】\n病情摘要及初步印象:\n患儿感冒后流黄涕2月初步诊断:鼻炎\n总结建议:\n建议用羟甲唑林喷雾剂,布地奈德喷雾剂交替喷鼻,口服头孢克肟,孟鲁司特
39     }
40   ],
41   "meta": {
42     "id": "29257",
43     "url": "https://www.haodf.com/doctorteam/flow_team_6477245131.htm"
44   },
45   "qwen_evaluation": {
46     "score": 42,
47     "quality_level": "低质量",
48     "reason": "医生未回应患者关于用药的核心诉求,对持续一月黄脓涕可能提示的鼻窦炎风险识别不足,缺乏具体治疗方案及就医指导,回答过于简略。",
49     "dimension_scores": {
50       "accuracy": 55,
51       "advice": 20
52     }
53   },
54   "qwen_score": 42

```

medium_quality.json:

```
2  {
3    "messages": [
24   {
25     "role": "user",
26     "content": "好的谢谢您\n\n我们从你们门诊开药后能拿到东营这边医院打吗，还是要开好处方才能打"
27   },
28   {
29     "role": "assistant",
30     "content": "写好病历，诊所应该能打的！"
31   },
32   {
33     "role": "user",
34     "content": "收到，谢谢您"
35   },
36   {
37     "role": "assistant",
38     "content": "肌肉注射可能有乏力，好好休息！"
39   },
40   {
41     "role": "user",
42     "content": "好的，谢谢主任\n\n主任您好，我和孩子打了一针二巯丙磺钠后稍微有点低热就没打了，现在跟孩子还是心慌，请问一下不打针驱汞的话我们可以吃些什么有助于排汞，我可以带他
43   },
44   {
45     "role": "assistant",
46     "content": "【诊断与建议】\n病情摘要及初步印象：\n打破体温表6支，头晕睡眠差半月。查体正常。尿汞21，17ug/L\n总结建议：\n诊断：汞吸收处理：二巯丙磺钠0.125肌注每日一次，
47   }
48 ],
49 "meta": {
50   "id": "29259",
51   "url": "https://www.haodf.com/doctorteam/flow_team_6477245133.htm"
52 },
53 "qwen_evaluation": {
54   "score": 62,
55   "quality_level": "中等",
56   "reason": "优点在于回复及时、方案具体且包含复查与环境建议；但存在严重缺陷，药名出现明显错别字（二巯丙磺钠应为二巯丙磺钠），远程指导肌肉注射用药对儿童存在安全隐患，且未评估
57   "dimension_scores": {
58     "accuracy": 60,
59     "advice": 70
60   }
61 },
62 "qwen_score": 62
```


3 个人数据集构建实践

目的：将学到的数据处理方法，迁移应用到你们组自己在 Lab 2 爬取的真实数据上。请选择提取你们小组在 Lab 2 爬取的一个原始数据，参考基线代码，编写属于你们自己的 `my_clean.py` 和 `my_filter.py`。

领域数据源与痛点分析：你们在 Lab2 爬取的数据数据源是什么？这些原始数据中，主要包含哪些“噪音”（如特定的网页标签、广告词、无意义的符号等）？

采用了上次实验中 `pretrain.jsonl` 的数据，来源于维基百科和 A+医疗百科。在数据爬取时已经过大模型过滤，实际上“噪音”几乎没有，只有少量 `html` 标签与广告词，主要是将相关图片进行了去除，只保留文本数据。

自定义清洗规则设计（代码展示）：针对你们数据的特有噪音，你们编写了哪些新的正则表达式或处理逻辑？

优化思路简述：在 `clean_global_noise(text)` 函数中，根据 `pretrain.jsonl` 中图像说明文本的格式进行了去除，保留通用噪音清理。图像说明文本格式形如“`images\\贅生物_6.jpg`”、“`images\\%E5%AE%AB%E9%A2%88%E7%99%8C_0.jpg`”等，仅有一处 `html` 标签与少量广告词，进行特殊剔除。

核心正则代码片段：


```

def clean_global_noise(text):
    """去除全局噪音和爬虫残留标记"""
    text = text.replace('\r\n', '\n').replace('\r', '\n')
    text = re.sub(r'\n{3,}', '\n\n', text)
    text = re.sub(r'[ \t\u3000]+', ' ', text)

    # 匹配 <think> ... </think> (支持大小写、内部有换行或空格)
    text = re.sub(r'<think>[\s\S]*?</think>', '', text, flags=re.IGNORECASE)
    # 去除图片相关残留
    text = re.sub(r'图像说明[:\s]*(icon|Feed-icon|可免费查阅).*$', '', text, flags=re.I)
    text = re.sub(r'图像说明[:\s]*編輯維基數據鏈接.*$', '', text, flags=re.I)
    text = re.sub(r'图像说明[:\s]*聽聽.*$', '', text, flags=re.I)
    text = re.sub(r'图像说明[:\s]*[\s^\n]*', '', text)
    text = re.sub(r'贅生物\s*-\s*图像说明[:\s]*[\s^\n]*', '', text, flags=re.I)
    text = re.sub(r'^肿瘤 - 图像说明:.*$', '', text, flags=re.M)
    text = re.sub(r'images?\[\[^\n]*\.\jpg.*$', '', text, flags=re.I)
    text = re.sub(r'%[0-9A-Fa-f]{2}', '', text)

    # 清理广告和推广性内容
    text = re.sub(r'可免费查阅.*$', '', text, flags=re.I)
    text = re.sub(r'广告|推广|点击查看', '', text, flags=re.I)

    # 通用噪音清理
    text = re.sub(r'(\d{4}-\d{2}-\d{2}填写)', '', text)
    text = re.sub(r'[\x00-\x09\x0b-\x0c\x0e-\x1f\x7f\u200b\u200c\u200d]+', '', text)
    return text

```

除此之外，还对输出格式与 main 函数进行了改变。

```

DataEngine > my_clean.py > clean_global_noise

def create_sft_record(text: str) -> dict | None:
    """将一段肿瘤科普文本转化为 SFT 格式 (user-assistant 对) """
    clean_content = clean_global_noise(text)
    if len(clean_content) < 100:      # 太短的直接丢弃
        return None

    # 构造合理的对话:
    # User: 请详细讲解以下肿瘤学知识
    # Assistant: 专业、结构化的解答
    user_prompt = (
        "以下是一段关于肿瘤（癌症）的专业医学知识，请你以专业肿瘤科医生的身份，"
        "用通俗易懂但准确的语言，为患者或医学生详细讲解这段内容，包括关键概念、临床意义和注"
        f"{clean_content}"
    )

    assistant_response = "好的，我将结合肿瘤病理学和临床知识，为您详细讲解上述内容。"

    messages = [
        {
            "role": "system",
            "content": "你是一位经验丰富的肿瘤科医生，擅长用专业且易懂的方式解释肿瘤相关知"
        },
        {
            "role": "user",
            "content": user_prompt
        },
        {
            "role": "assistant",
            "content": assistant_response
        }
    ]

# 跳过所有带图片的记录
if 'image' in item:
    stats['image_skipped'] += 1
    continue

```

最终数据集产出展示：生成至少 **100 条** 格式正确的 JSON 数据，并至少包含 **15 条** 被大模型评定为 high_quality.json 的优质数据。

```
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python\SocialMedia\Lab3_DataEngine> python my_filter_llm.py
✓ 全部数据（含评分）已保存
```

```
=====
筛选完成
=====
```

```
高质量(≥75分): 171 条 (35.8%)
中等(60-74分): 129 条 (27.0%)
低质量(<60分): 177 条 (37.1%)
=====
```

```
平均分: 66.5
最高分: 95
最低分: 25
=====
```

```
全部完成！
```

```
29     {
30         "messages": [
31             {
32                 "content": "你是一位经验丰富的肿瘤科医生，擅长用专业且易懂的方式解释肿瘤相关知识",
33             },
34             {
35                 "role": "user",
36                 "content": "以下是一段关于肿瘤（癌症）的专业医学知识，请你以专业肿瘤科医生的身份",
37             },
38             {
39                 "role": "assistant",
40                 "content": "好的，我将结合肿瘤病理学和临床知识，为您详细讲解上述内容。"
41             }
42         ],
43         "meta": {
44             "id": 4,
45             "source": "data_pretrain.jsonl",
46             "type": "tumor_knowledge"
47         },
48         "qwen_evaluation": {
49             "score": 55,
50             "quality_level": "低质量",
51             "reason": "存在基础病理概念混淆（如将细胞适应机制与肿瘤发生机制不当等同），部分术",
52             "dimension_scores": {
53                 "accuracy": 45,
54                 "depth": 50,
55                 "logic": 70,
56                 "education": 50,
57                 "language": 80,
58                 "completeness": 60
59             }
60         }
61     }
```

```
2 {
3   "messages": [
4     {
5       "role": "system",
6       "content": "你是一个专业的医学知识助手，擅长解答各种医学问题。"
7     },
8     {
9       "role": "user",
10      "content": "以下是一段关于肿瘤（癌症）的专业医学知识，请你以专业肿瘤科医生的身份，用通俗易懂但准确的语言，为患者或医学生详细讲解这段内容，包括关键概念、发病机制、诊断方法和治疗策略。"
11    },
12    {
13      "role": "assistant",
14      "content": "好的，我将结合肿瘤病理学和临床知识，为您详细讲解上述内容。"
15    }
16  ],
17  "meta": {
18    "id": 5,
19    "source": "data_pretrain.jsonl",
20    "type": "tumor_knowledge"
21  },
22  "qwen_evaluation": {
23    "score": 82,
24    "quality_level": "高质量",
25    "reason": "内容涵盖病因、分子机制及转移过程，核心医学知识准确，术语使用规范；但段落间逻辑衔接略显生硬，从致癌因素直接跳跃至转移机制缺乏过渡，且部分表述过于专业，可能对部分患者造成理解困难。",
26    "dimension_scores": {
27      "accuracy": 88,
28      "depth": 85,
29      "logic": 75,
30      "education": 80,
31      "language": 85,
32      "completeness": 80
33    }
34  }
```

4 工程反思与代码剖析 (20%)

目的： 对比不同数据源在清洗和评估时的挑战。

问题 1： 在处理你们自己的爬虫数据时，有没有遇到基于规则（正则表达式）很难清洗，甚至引发把有用信息删掉的情况？如果有，你们最终是如何取舍的？

答：图像说明信息在爬取时，有很多都是无效信息，直接将所有图片记录进行跳过。

问题 2： 大模型在评估你们领域的对话质量时，是否出现了“误判”（比如你们觉得很好的数据，大模型给了低分）？如果有，你认为大模型缺乏该领域的背景知识，还是你们的 Prompt 设定不够严谨？

答：有，比如“在病理学中，赘瘤是一个专业术语，其英文表述包含 vegetation，这一名称源于其形态与自然植被的相似性。肿瘤疾病的分类遵循国际疾病肿瘤学分类（International Classification of Diseases for Oncology）标准。历史临床数据显示，一九五八年曾完成颅内赘瘤二百六十六例的临床分析。一九六八年至一九七九年间，存在针对口腔及咽恶性赘瘤的死亡分析记录。在现代诊疗技术研究中，可视喉镜联合光棒方案已应用于咽喉部新生物患者的临床可行性评估。相关研究资料见于中华神经精神科杂志、复旦学报医学版等学术期刊及台湾大学公共卫生学院学位论文，时间跨度从一九五八年延续至二零二零年。”，其打低分的理由为“术语定义错误（肿瘤不应译为 vegetation），内容系文献片段堆砌，缺乏病理机制与诊疗核心知识，逻辑混乱且无实际教学意义。”前一句为大模型缺乏该领域的背景知识，后面部分则是对 prompt 设定的严格场景要求。实际上，打低分的数据中很多是由于 API 错误或网络报错，低分数据占少数，并且以大模型缺乏该领域的背景知识为主。