

廈門大學



信息学院

《社交网络技术与应用》

作业二 数据爬取

实验题目 数据爬取

组 员 37220232203780 马鑫 (负责 CPT 持续预训练阶段)

11920232202682 郑彤轩 (负责 SFT 微调阶段)

11920222202480 徐梓宸 (负责 KB 知识库阶段)

37220232203919 张琳 (负责 EVAL 评测阶段)

1 实验介绍

在医疗大模型 (如医疗视觉语言模型 VLM) 的训练和优化过程中, 高质量的数据集是核心驱动力。本实验结合传统 Python 爬虫技术与大模型 (LLM/VLM) 强大的语义理解能力, 将混乱的网页文本和图像转化为模型训练四个特定阶段 (持续预训练、微调、知识库、评测) 所需的标准数据集。

实验目的

- 了解并体会大模型在实际数据工程的应用
- 了解不同阶段大模型训练数据的构建方法
- 掌握使用 Python 进行数据爬取的技术

实验清单

实验	简述	难度	软件环境	开发环境
爬虫	访问公开医疗网站, 提取包含图文的 HTML 内容	初级	Python 3	本地PC
数据构建	使用 VLM 处理网页内容, 生成四种不同格式的医疗数据集	中级	Python 3	本地PC

2 实验设计与数据源说明 (20%)

数据主题选型：请简述你选择的医疗子领域及选择理由。

CPT：

维基百科、A+医学百科等平台对各类肿瘤词条收录全面，文本质量高、图文资料充足，便于多模态数据提取，并且肿瘤词条中包含大量医学影像，适合开展图文对其的多模态数据集构建。

SFT：

本次实验选择了肿瘤学（Oncology）作为医疗子领域。

理由：选择该领域的主要原因在于其数据的高度复杂性与极强的问答需求。肿瘤学涉及恶性肿瘤的诊断（如病理分析、影像学检查）、复杂治疗方案以及长期的随访管理。这些专业知识在公开网络中虽然丰富，但往往分散且伴随大量非医学干扰信息。通过构建该领域的 SFT（指令微调）数据集，可以有效模拟真实医患场景，训练模型在面对患者焦虑性提问时，能够输出既具备医学严谨性又富有同理心的专业建议，具有极高的临床辅助与科普价值。

KB：

- 肿瘤具有高发病率与高危害性，是全球重大公共卫生问题，AI 辅助诊断、预后评估、个性化治疗等研究具有重要临床价值。
- 肿瘤领域数据类型丰富，涵盖文本、影像、基因等多模态信息，可有效支撑深度学习模型训练。
- 该领域公开数据库、期刊文献及诊疗规范较为完善，数据可获取性强、标准化程度高，便于构建高质量数据集。
- 肿瘤 AI 研究已形成成熟范式，模型应用场景明确，研究成果易于转化与验证，对提升医学 AI 实用性与科研创新性具有显著意义。

EVAL：

- 临床与社会价值突出：肿瘤发病率、死亡率高，诊疗决策复杂，大模型在辅助诊断、用药指导、预后评估等场景应用需求迫切。
- 数据标准化程度高：拥有 TNM 分期、WHO 分类、NCCN/CSCO 指南等统一规范，数据标签清晰、噪声低，便于模型训练。
- 数据维度丰富：涵盖文本病历、文献、病理影像、基因组学等多模态数据，适配多模态大模型训练。
- 公开合规数据源充足：TCGA、SEER 等权威脱敏数据集丰富，可降低隐私合规风险，适合科研训练。
- 科研转化空间广：可助力新药研发、临床试验设计、肿瘤防控等，落地场景明确，行业与政策支持度高。

数据源及目标网站：请列出你实际爬取了哪些目标网站，写出它们的名称及代表性 URL 链接。

CPT:

维基百科：[赘生物 - 维基百科，自由的百科全书](#)

A+医学百科：[宫颈癌 - A+医学百科](#)

SFT:

肿瘤学的核心词条入口：

<https://baike.baidu.com/item/%E8%82%BF%E7%98%A4%E5%AD%A6/17792532>

利用递归爬取技术延伸至具体的癌症词条如

肺癌 <https://baike.baidu.com/item/%E8%82%BA%E7%99%8C/106649>、

肝癌 <https://baike.baidu.com/item/%E8%82%9D%E7%99%8C/141011>

以及关键治疗手段如

化学治疗

<https://baike.baidu.com/item/%E5%8C%96%E5%AD%A6%E6%B2%BB%E7%96%97/2827154>

放射治疗

<https://baike.baidu.com/item/%E6%94%BE%E5%B0%84%E6%B2%BB%E7%96%97/1012984>

KB:

肿瘤学的核心词条 URL:

<https://baike.baidu.com/item/%E8%82%BF%E7%98%A4%E5%AD%A6/17792532>

EVAL:

名称：A+医学百科

链接：www.a-hospital.com

爬虫字段分析：在目标网页中，主要提取了哪些 HTML 标签或内容？

CPT:

<h1>标题

<div>正文内容

<p>段落

<h2><h3><h4>所有标题

所有列表

<tr>基本信息表格

<table>基本信息框

<th>字段名

<td>字段值

图片

src 图片 URL ， alt 图片说明文字

SFT:

针对目标网页的 HTML 结构，主要通过 BeautifulSoup 精准提取了代表条目名称的 <h1> 标题标签、类名为 lemmaSummary 的摘要段落以及包含深度医学描述的 main-content 或 J-summary 核心正文容器，同时为了实现自动化扩展，程序深入解析了带有 innerLink 属性的 <a> 标签，通过正则匹配和文字白名单过滤（如“癌”、“瘤”、“靶向”），确保只在肿瘤专业词条间进行跳转，从而排除了医院广告、地理信息或荣誉奖励等无关干扰，最终提炼出高质量的医学文本作为 AI 生成 SFT 问答对的原始语料。

KB:

1. 核心标识字段：提取<h1>标题标签，获取词条名称（即肿瘤病种、诊疗术语名称），作为知识库知识块的核心标识，对应代码中`soup.find('h1').get\_text(strip=True)`，用于知识库中“disease”字段及知识块分类，确保每个知识块可精准定位到具体肿瘤相关词条；

2. 核心文本字段：针对百度百科新老两版页面结构，重点提取两类核心正文容器标签，作为知识库文本内容的核心来源：一是类名为“mainContent_sCMp6”的div标签，二是id为“J-lemma-main-wrapper”的div标签，对应代码中`main = soup.find('div', class\_='mainContent\_sCMp6') or soup.find('div', id='J-lemma-main-wrapper')`，提取容器内所有文本后，通过`clean\_text\_rule`函数过滤冗余信息，最终作为知识库知识块“content”字段的原始语料，支撑后续 DeepSeek API 的结构化提取；

3. 辅助多媒体字段：提取核心正文容器内的标签，获取医学配图相关信息，包括图片 url (data-src 或 src 属性)、图片说明 (alt 属性)，对应代码中`main.find\_all('img')[:3]`，筛选医学配图，存储图片本地路径、url 及说明，作为知识库知识块的“images”字段，丰富知识库的多模态数据，适配后续 RAG 检索的可视化需求；。

4. 数据源追溯字段：提取当前词条的 URL 链接，对应代码中构建的`url = f"https://baike.baidu.com/item/{quote(disease\_name)}"`, 作为知识库知识块 "metadata" 中的 "url" 字段，实现数据来源可追溯，同时契合爬虫合规要求，也为知识库后续动态更新、数据校验提供依据。

EVAL:

- 1.主体容器：优先抓取 <div id="bodyContent"> 标签（无则使用 <body> 标签）作为内容载体；
- 2.图片相关：提取 <div class="thumb">（带图注图片容器）、内部 标签（图片链接）、<div class="thumbcaption">（图片描述）；同时提取段落内 标签（图片链接 + alt 描述）；
- 3.文本内容：观察发现主要文本内容都位于 <p> 段落标签内；

请跑通代码后，生成的数据集文件中的代表性数据截图（或直接粘贴数据集片段）展示在下方，并附上简单的代码运行终端截图。

[illegible]

```

(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python> python SocialMedia\dataacrawl.py
[*] 爬取词条: 食道癌
[*] 开始构建数据集: 【食道癌】
API 错误: Expecting value: line 1 column 2 (char 1)
API 返回空内容, 跳过处理
    预训练 (PT) 数据生成完成
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python> python SocialMedia\dataacrawl.py
[*] 爬取词条: 肠癌
[*] 开始构建数据集: 【肠癌】
    预训练 (PT) 数据生成完成
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python> python SocialMedia\dataacrawl.py
[*] 爬取词条: 癌基因
[*] 开始构建数据集: 【癌基因】
    预训练 (PT) 数据生成完成
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python> python SocialMedia\dataacrawl.py
[*] 爬取词条: 鼻咽癌
[*] 开始构建数据集: 【鼻咽癌】
    预训练 (PT) 数据生成完成
(E:\Social Media Technoledge and application\lab_3780) PS E:\code\vscode\Python> python SocialMedia\dataacrawl.py
[*] 开始构建数据集: 【癌症】
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 返回空内容, 跳过处理
API 错误: Expecting value: line 1 column 1 (char 0)
API 返回空内容, 跳过处理
    预训练 (PT) 数据生成完成

```

SFT（微调）成果展示

```
run_sft x
```

```
[+] 成功生成 5 条对话
[*] 处理词条：肾癌 | 队列剩余：905 | 进度：441/500
[+] 成功生成 5 条对话
[*] 处理词条：膀胱肿瘤 | 队列剩余：913 | 进度：446/500
[+] 成功生成 5 条对话
[*] 处理词条：乳头状肾细胞癌 | 队列剩余：914 | 进度：451/500
[+] 成功生成 5 条对话
[*] 处理词条：肾细胞癌 | 队列剩余：913 | 进度：456/500
[+] 成功生成 5 条对话
[*] 处理词条：宫颈癌 | 队列剩余：924 | 进度：461/500
[+] 成功生成 10 条对话
[*] 处理词条：肿瘤细胞 | 队列剩余：1041 | 进度：471/500
[+] 成功生成 5 条对话
[*] 处理词条：瘤细胞 | 队列剩余：1040 | 进度：476/500
[+] 成功生成 5 条对话
[*] 处理词条：原发性肝癌 | 队列剩余：1041 | 进度：481/500
[+] 成功生成 5 条对话
[*] 处理词条：化学致癌剂 | 队列剩余：1052 | 进度：486/500
[+] 成功生成 1 条对话
[*] 处理词条：胃癌 | 队列剩余：1067 | 进度：487/500
[+] 成功生成 5 条对话
[*] 处理词条：肿瘤特异性移植抗原 | 队列剩余：1069 | 进度：492/500
[+] 成功生成 5 条对话
[*] 处理词条：细胞癌变 | 队列剩余：1083 | 进度：497/500
[+] 成功生成 5 条对话
[*] 任务完成！共生成 500 条肿瘤学数据，保存在 oncology_sft_data.jsonl.
```

[illegible]

数据成果：在此处贴上你生成的 data 片段截图

```
crawler.py 7 data_eval.jsonl x generator.py 1 convert_to_jsonl.py main.py
data_eval.jsonl
1 [{"question": "48岁男性患者发现右侧大腿皮下肿物5年，肿物逐渐增大至直径约10cm，无明显疼痛，查体边界清晰，活动度可。该肿物最可能的性质是？",
2  "question": "某患者行结肠镜检查时发现直肠黏膜表面有一突出于肠腔的息肉样肿物，该肿物的生长方式应为？", "options": {"A": "外生性生长", "B":
3  "question": "病理医师通过肿瘤组织的哪一变化来识别其组织来源、进行分类命名，并确定良恶性程度？", "options": {"A": "肿瘤实质", "B": "肿瘤
4  "question": "48岁女性因左侧乳腺癌就诊，术中发现肿瘤周围纤维组织增生导致乳头痛，该收缩功能最可能来源于哪种细胞？", "options": {"A": "纤
5  "question": "70岁男性因结肠占位手术切除，病理提示肿瘤细胞分化程度较低，形态大小差异极大，无法确定其组织来源，该肿瘤属于？", "options": {
6  "question": "62岁女性因食管黏膜脱落活检，病理报告显示食管黏膜组织与正常食管黏膜差异显著，癌细胞类型性明显，该异型的临床意义是？", "options": {
7  "question": "62岁女性因子宫内腺癌行子宫全切术，术后病理提示肿瘤已发生远处转移，该患者最终因肿瘤死亡的最主要原因是？", "options": {"A": "
8  "question": "某患者行肺穿刺活检，病理提示见瘤细胞呈嗜碱性胞浆，核大深染，可见不对称性核分裂象。下列哪项改变对该恶性肿瘤的诊断具有关键意义
9  "question": "子宫平滑肌瘤作为常见的良性妇科肿瘤，其病理诊断的主要依据是？", "options": {"A": "可见大量病理性核分裂象", "B": "瘤细胞排列
10 "question": "患者男，65岁，因排便习惯改变、便血1个月就诊，结肠镜检查发现结肠占位，病理活检提示结肠腺癌。该肿瘤对规范化疗敏感性较低的主要原
11 "question": "患者女，28岁，因左侧颈部无痛性进行性增大肿块2周就诊，淋巴结活检证实为弥漫大B细胞淋巴瘤（高度恶性淋巴瘤），该肿瘤对化疗高度敏
12 "question": "患者男，55岁，确诊肺癌后接受一线化疗6个月，复查胸部CT及全身PET-CT提示原发病灶增大且出现脑转移，该病情进展的核心生物学基础，
13 "question": "62岁女性体检时超声发现左侧卵巢内实限有一直径1.8cm的肿物，质地偏韧，边界清晰，活动度良好，近1年生长速度无明显加快。该肿瘤最
14 "question": "58岁男性因进展期胃癌行根治性胃大部切除术，术中留取腹腔冲洗液行细胞学检查，结果发现癌细胞。该肿瘤的扩散方式属于？", "options":
15 "question": "72岁女性因舌颈接触性出血就诊，妇科检查发现宫颈有菜花状肿物，触之易出血，活检病理提示为宫颈鳞状细胞癌。关于该患者的生长方
16 "question": "患者男，52岁，确诊甲状腺癌后完善全身影像学检查提示仅存在骨转移灶，无其他远处转移，根据肿瘤生物学播散的相关理论，该患者肿瘤出现
17 "question": "病理科医师在镜下观察乳腺癌组织的局部浸润过程，可见癌细胞先降低细胞间粘附力，随后与基底膜紧密附着，接下来发生的核心病理变化是
18 "question": "某28岁青年男性因家族性结直肠癌发病，遗传咨询医师告知其患结直肠癌的风险显著升高，这一临床现象最能支持以下哪种关于肿瘤本质
19 "question": "一名56岁男性因便秘就诊，结肠镜检查发现结肠占位，病理提示腺癌，术后基因检测显示肿瘤组织中p53基因存在等位基因缺失及点突变，该基因属于
20 "question": "研究发现某肺癌细胞中表皮细胞生长因子受体（EGFR）的表达水平显著高于正常支气管上皮细胞，且其编码基因未发生结构突变，该原癌基因
21 "question": "52岁女性，平素喜食肉类蔬菜、腌熏食品及烧烤，近2个月出现上腹饱胀、黑便，胃镜活检确诊为胃癌。该患者的肿瘤发生与下列哪类化学致
22 "question": "70岁女性卵巢浆液性囊腺癌患者，体外培养其肿瘤细胞可连续传代超过50次仍保持旺盛增殖活性，该细胞的无限增殖特性主要依赖于？", "op
```

[illegible]

KB 知识库（微调）成果展示：

{ "id": "doc_3f6d5d_deaf",	"content": "【疾病概述】肺癌是发病率和死亡率增长最快、对人群健康和生命威胁最大的恶性肿瘤之一。近50年来，许多国家的肺癌发病率和死亡率均明显上升。"
{ "id": "doc_3f6d5d_ef26",	"content": "【发病机制/病因】肺癌的病因尚不完全明确，但大量研究证实了多种高危因素，吸烟是最重要的高危因素，烟草中含有超过3000种化学物质，其中
{ "id": "doc_3f6d5d_d2d4",	"content": "【临床表现/症状】肺癌的临床表现多样，主要分为以下几类：\n1. 局部症状：由肿瘤局部生长刺激、阻塞、浸润和压迫引起，\n① 咳嗽：最早
{ "id": "doc_3f6d5d_0a1f",	"content": "【推荐疗法/治疗方案】肺癌的治疗强调多学科综合治疗（MDT）模式，治疗前进行准确的临床分期至关重要。治疗方案根据肺癌的组织学类型、分
{ "id": "doc_76bd59_140f",	"content": "【疾病概述】非小细胞肺癌是肺癌中最常见的类型，约占所有肺癌的80%。它主要包括鳞状细胞癌（鳞癌）、腺癌和大细胞癌，与小细胞肺癌相比，
{ "id": "doc_76bd59_b1ba",	"content": "【发病机制/病因】非小细胞肺癌的发病是多种因素共同作用的结果，吸烟被公认为最重要的高危因素，烟草中的多链芳香烃类化合物（如苯并芘）
{ "id": "doc_76bd59_c367",	"content": "【临床表现/症状】非小细胞肺癌的临床表现多样，早期症状常较轻微或不典型，常见症状包括：1. 咳嗽：多为刺激性干咳，因肿瘤生长于支气管管
{ "id": "doc_76bd59_fbfe",	"content": "【推荐疗法/治疗方案】非小细胞肺癌的治疗需根据分期、病理类型、患者全身状况等制定个体化综合方案，1. 外科手术：是早期（I-II期）和部
{ "id": "doc_acb64b_89b8",	"content": "【疾病概述】小细胞肺癌（Small Cell Lung Cancer, SCLC）是一种源于肺部的低分化神经内分泌恶性肿瘤，约占肺癌总发病率的15%-20%。显
{ "id": "doc_acb64b_47d7",	"content": "【临床表现/症状】小细胞肺癌的临床表现可由局部原发灶侵犯、邻近结构压迫、远处转移或副肿瘤综合征引起。典型症状包括刺激性干咳、胸痛、
{ "id": "doc_cea5ba_bfe5",	"content": "【推荐疗法/治疗方案】小细胞肺癌的治疗方案取决于疾病分期、患者整体健康状况等。诊断必须由经验丰富的肺癌病理学家评估，免疫组化（如Ki
{ "id": "doc_cea5ba_ef3d",	"content": "【疾病概述】肺腺癌（Lung adenocarcinoma）是肺癌中最常见的类型，占肺癌总数的40%-55%。它主要起源于支气管黏膜上皮及黏膜腺，多数患
{ "id": "doc_cea5ba_9901",	"content": "【发病机制/病因】肺腺癌的确切病因尚不明确，其发生被认为是多种基因及外界因素长期相互作用形成的复杂病理过程。主要相关因素包括：1. 吸
{ "id": "doc_cea5ba_2261",	"content": "【推荐疗法/治疗方案】肺腺癌治疗遵循多学科综合治疗与个体化治疗相结合的原则，依据肿瘤分期、病理类型、分子特征及患者体能状况制定方案
{ "id": "doc_fd7b7b_ce67c",	"content": "【疾病概述】肺鳞癌，全称肺鳞状细胞癌，是肺癌中最常见的病理类型之一，约占所有肺癌的40%~51%。该病多见于老年男性，其发生与吸烟有极
{ "id": "doc_fd7b7b_ce98",	"content": "【发病机制/病因】肺鳞癌的主要病因是长期吸烟，烟草中的致癌物质（如多环芳烃、亚硝胺等）是导致支气管黏膜上皮鳞状化生、异型增生直至癌
{ "id": "doc_fd7b7b_f0b2",	"content": "【临床表现/症状】肺鳞癌的临床表现多样，常见症状包括：1. 咳嗽：最常见，约35%~75%患者有首发症状，咳嗽性质改变，如呈高音调金属音
{ "id": "doc_fd7b7b_5c33",	"content": "【推荐疗法/治疗方案】肺鳞癌的治疗需根据分期、患者身体状况等综合制定，1. 外科治疗：是早期（I、II期及部分III期）肺鳞癌的首选和主要
{ "id": "doc_8e3bfb_475f",	"content": "【疾病概述】胸膜间皮瘤是一种来源于胸膜间皮细胞的原发性肿瘤，占胸膜肿瘤的5%，临床较为少见。该肿瘤可发生于脏层胸膜和壁层胸膜的任何
{ "id": "doc_8e3bfb_2626",	"content": "【发病机制/病因】胸膜间皮瘤的发生是环境、生物和遗传因素共同作用的结果。石棉已被国际癌症研究中心确定为明确的致癌物，在西方国家被认为是
{ "id": "doc_8e3bfb_43f2",	"content": "【临床表现】胸膜间皮瘤的临床表现与影像学特征密切相关。其核心影像学表现包括：1. 胸膜增厚，可为局限性或弥漫性，形态呈椭圆形、结节状
{ "id": "doc_dba7a8_ae87",	"content": "【疾病概述】纵隔肿瘤是临床胸部常见疾病，包括原发性肿瘤和转移性肿瘤两大类。原发性纵隔肿瘤是指起源于纵隔内各种组织结构（如胸腺、神经
{ "id": "doc_dba7a8_7be6",	"content": "【推荐疗法/治疗方案】纵隔肿瘤的治疗原则主要依据肿瘤的性质（良性或恶性）、病理类型、分期及患者全身状况制定。手术治疗是绝大多数原发
{ "id": "doc_81dc1f_d91d",	"content": "【疾病概述】食管癌是常见的消化道恶性肿瘤，其发病率和死亡率在全球范围内差异显著。我国是世界上食管癌高发地区之一，每年平均病死约15
{ "id": "doc_81dc1f_291d",	"content": "【发病机制/病因】食管癌的病因复杂，目前认为是多种因素共同作用的结果，尚无单一决定性因素。主要危险因素包括：1. 化学致癌物：亚硝胺
{ "id": "doc_81dc1f_a11e",	"content": "【临床表现/症状】食管癌早期症状常不明显且不典型，可表现为吞咽粗糙食物时的轻微不适感，如梗噎感、停滯感或异物感，胸骨后烧灼样、针刺
{ "id": "doc_d68729_b515",	"content": "【疾病概述】原发性肝癌（primary hepatic carcinoma）是起源于肝脏的恶性肿瘤。我国东南沿海地区及福建省为高发区，好发于40~60岁人群
{ "id": "doc_d68729_b3e5",	"content": "【发病机制/病因】原发性肝癌的病因和发病机制因肿瘤类型而异。原发性纵隔肿瘤的病因而不完全明确，可能与遗传因素、环境暴露、免疫异常等有
{ "id": "doc_d68729_d4f2",	"content": "【推荐疗法/治疗方案】原发性肝癌的治疗原则主要依据肿瘤的性质（良性或恶性）、病理类型、分期及患者全身状况制定。手术治疗是绝大多数原发
{ "id": "doc_6e082f_abe3",	"content": "【疾病概述】食管癌是常见的消化道恶性肿瘤，其发病率和死亡率在全球范围内差异显著。我国是世界上食管癌高发地区之一，每年平均病死约15
{ "id": "doc_6e082f_6e76",	"content": "【发病机制/病因】食管癌的病因复杂，目前认为是多种因素共同作用的结果，尚无单一决定性因素。主要危险因素包括：1. 化学致癌物：亚硝胺
{ "id": "doc_6e082f_dda0",	"content": "【临床表现/症状】食管癌早期症状常不明显且不典型，可表现为吞咽粗糙食物时的轻微不适感，如梗噎感、停滯感或异物感，胸骨后烧灼样、针刺
{ "id": "doc_6e082f_c1b1",	"content": "【疾病概述】原发性肝癌（primary hepatic carcinoma）是起源于肝脏的恶性肿瘤。我国东南沿海地区及福建省为高发区，好发于40~60岁人群
{ "id": "doc_6e082f_1dc0",	"content": "【推荐疗法/治疗方案】原发性肝癌的治疗原则主要依据肿瘤的性质（良性或恶性）、病理类型、分期及患者全身状况制定。手术治疗是绝大多数原发
{ "id": "doc_9fb803_937f",	"content": "【疾病概述】胆管癌是发生于胆管黏膜上皮的恶性肿瘤，在胆道恶性肿瘤中占首位。原发性胆管癌在临床上较为少见，根据国内报道，仅占所有恶性

```
[*] 正在搜索与抓取百科词条：【癌性疼痛】
[~] 百科内容提取成功。正交给 DeepSeek 分析核心医疗维度（思考中）...
[√] 成功写入 4 个结构化切块! (当前总进度: 285/500)
[zZz] 休眠 4.5 秒，保护本地 IP...

[*] 正在搜索与抓取百科词条：【肿瘤恶病质】
[~] 百科内容提取成功。正交给 DeepSeek 分析核心医疗维度（思考中）...
[√] 成功写入 4 个结构化切块! (当前总进度: 289/500)
[zZz] 休眠 2.7 秒，保护本地 IP...

[*] 正在搜索与抓取百科词条：【恶性胸水】
[~] 百科内容提取成功。正交给 DeepSeek 分析核心医疗维度（思考中）...
[√] 成功写入 4 个结构化切块! (当前总进度: 293/500)
[zZz] 休眠 2.7 秒，保护本地 IP...

[*] 正在搜索与抓取百科词条：【癌性发热】
[~] 百科内容提取成功。正交给 DeepSeek 分析核心医疗维度（思考中）...
[√] 成功写入 4 个结构化切块! (当前总进度: 297/500)
[zZz] 休眠 3.8 秒，保护本地 IP...

[*] 正在搜索与抓取百科词条：【上腔静脉综合征】
[~] 百科内容提取成功。正交给 DeepSeek 分析核心医疗维度（思考中）...
[√] 成功写入 4 个结构化切块! (当前总进度: 301/500)
[zZz] 休眠 3.1 秒，保护本地 IP...
```

【本项考核定量要求】： 为保证工程实践质量，对应产出的数据集需满足：

CPT (持续预训练)：至少包含 500 条 清洗后的高质量医学文本段落。

SFT (微调)：至少生成 500 对 符合 JSON 格式的医患问答对话。

KB (知识库)：至少包含 500 个 带有完善 Metadata 的切片条目。

Eval (评测)：至少生成 500 道 不重复的医学单项选择题。

4 工程反思与代码剖析 (20%)

目的： 培养独立排查工程环境报错的能力，以及对深度学习底层参数的理解。

问题 1：多模态数据的真正落地（图文结合） 本实验手册的背景是大模型时代的“多模态”医疗数据构建。然而，示例代码目前仅演示了纯文本的爬取与清洗。

思考： 要求将网页中的医学影像（X 光、CT 图、皮肤病理图等）与对应的文本描述一一对应提取出来，你应该如何修改 BeautifulSoup 的解析逻辑？如果进一步要求使用大模型对这些图片进行解读和清洗，你需要如何优化实验代码？（在此填写你们的思考/优化后的代码）

以 EVAL 为例：

观察网页代码得知，A+ 医学百科网页中的图片字段仅有两种情况：

```
><p>...</p>
▼<p>
   == $0
</p>
▶<p>...</p>
```

1. 要么存放在<p>标签中，并且带有img的tag，其alt字段为图片描述，src字段为图片url；

```
▼<div class="thumb tright">
  ▼<div class="thumbinner" style="width:202px;">
    ▼<a href="/w/%E6%96%87%E4%B8%B6:Bki3k.jpg" class="image">
       == $0
    </a>
    ▶<div class="thumbcaption">...</div>
  </div>
</div>
▶<p>...</p>
```

2. 要么存放在thumb标注中，同样带有明显的“img的tag,src字段为图片url”，但描述位于thumbcaption；

故对上述两种情况，先特殊寻找div并用正则匹配thumb，根据img的tag找到其src进行爬取下载，在去thumbcaption里找图片描述；而在正文中搜寻<p>标签的同时，查找img tag并执行上述流程，继而完成图片数据及其相应描述的获取

在生成最终的JSON Chunk时，不只存纯文本，而是构建图文对对象，将数据结构设计为：{"chunk_text": "正文内容...", "associated_images": [{"path": "1.jpg", "caption": "肺癌CT图"}]}，实现影像与其上下文语境的物理绑定

由于选择的网站比较优秀，正文中不会含有图片，故本次不需要额外清洗，但是可以使用vlm自行判断图片是否和医学有关来进行简单的清洗，或是通过判断图像文件大小来初步筛选

为了使vlm解读图片，将要上传的图片base64encode，然后在message的content中添加

```
{
  "type": "image_url",
  "image_url": {
    "url": f"data:image/jpeg;base64,{base64_image}"
  }
}
```

字段（或者豆包的数组里放很多个）

image string/array

doubao-seedream-3.0-t2i 不支持该参数

输入的图片信息，支持 URL 或 Base64 编码。其中，doubao-seedream-5.0-lite/4.5/4.0 支持单图或多图输入（[查看多图融合示例](#)），doubao-seededit-3.0-i2i 仅支持单图输入。

- 图片URL：请确保图片URL可被访问。
- Base64编码：请遵循此格式 `data:image/<图片格式>;base64,<Base64编码>`。注意 `<图片格式>` 需小写，如 `data:image/png;base64,<base64_image>`。

问题 2：长文本截断与关键医学信息丢失 在生成“微调数据”和“评测数据”时，为了防止大模型 API 的 Token 数量超限，示例代码采用了直接硬截断的方式（即 `data['full_text'][:2000]`）。

思考： 医疗词条可能很长，硬截断极易导致文章后半部分（如“治疗方案”、“并发症”）核心信息丢失。（在此填写你们的优化思路/优化后代码）

SFT:

在面对医疗长词条截断导致关键信息丢失的问题时，代码虽然在 `scrape_page` 函数中保留了 `clean_text[:3500]` 这一初步的硬截断逻辑，但实际上通过多重优化思路缓解了核心医学信息的遗失风险。首先，代码在抓取阶段并非盲目截断，而是通过 BeautifulSoup 精准定位了 lemmaSummary（摘要）和 mainContent（正文）两个关键容器，并优先将摘要信息置于正文之前；由于医学百科的编写习惯通常会将疾病的定义、核心特征和最主要的治疗原则置于开篇摘要中，这种“摘要优先”的策略确保了即使发生截断，模型接收到的也是该词条最精炼的“干货”信息。

进一步的优化思路在于语义优先的智能分段与选择性保留。在处理肿瘤学这种极长篇幅的内容时，与其进行物理长度的强制切分，不如引入针对医学目录的选择性抓取逻辑，例如优先提取 HTML 中包含“治疗方案”、“临床表现”或“预后管理”等关键小标题（h2, h3）下的段落。在代码工程层面，可以引入滑动窗口技术或关键段落提取算法，利用关键词密度过滤，剔除词条中关于“历史背景”、“社会影响”等非临床维度的冗余信息，将宝贵的 Token 额度留给“用法用量”或“生存率分析”等核心医学内容。

此外，为了彻底解决单次生成带来的信息局限性，可以采用递归生成或多段并行处理的逻辑。代码可以将长文本按语义章节切分为多个子块，分别发送给大模型生成对应的问答对，最后进行汇总去重。在当前的 Prompt 设定中，通过引导 AI 模拟“化疗副作用处理”或“靶向药耐药”等具体场景，实际上是在后端利用了大模型自身的推理能力，促使模型在 3500 字的有限窗口内聚焦于最具临床价值的冲突点。未来可以通过增加长文本摘要代理，先由一个较轻量级的模型将万字长文压缩成关键点列表，再交由高性能模型进行 SFT 问答对转换，从而在保证 Token 不超限的前提下，实现医疗知识全链路的覆盖。

EVAL:

由于医学百科的知识结构极其严谨，天然按照 `<p>`（段落）进行排版。我们在 BeautifulSoup 解析时，不再提取整个网页的 `.text`，而是通过 `find_all('p')` 逐段提取。这保证了任何切分动作都不会破坏一个完整句子的内部逻辑

同时设定一个安全的 Token 阈值（如 `chunk_size = 800` 字符）。算法会逐个读取提取出的段落（Paragraph），并将其拼接。当加入下一个段落会导致总长度超过 800 时，立刻封存当前 Chunk，并开启下一个新 Chunk 的拼接

经过上述处理后能完美拆解出多个长度均匀、语义连贯的独立 Chunk。在调用大模型生成评测题目时，通过遍历所有块，绕开了单次 API 的 Token 限制，还确保了疾病生命周期的每一个环节都能生成对应的测试题

KB:

一是构建医疗核心信息知识库词典，提前录入肿瘤领域关键术语（如治疗方案、并发症、病理分型等），在分段截断前，通过知识库匹配定位核心信息，确保此类内容优先保留，避免因截断遗漏；二是优化知识库分级管理，将医疗文本段落与知识库标签关联，按“核心信息-重要信息-冗余信息”分级，为分段优先级排序提供知识库支撑，让分段限额更具针对性；三是建立知识库动态更新机制，同步爬取的肿瘤领域新数据、新术语，实时补充至知识库，确保分段截断时对新型诊疗方案、并发症等信息的精准识别；四是新增知识库校验模块，截断后通过知识库比对，校验核心信息是否完整保留、术语是否准确，避免因截断导致的信息偏差，同时联动微调数据与评测数据，确保知识库与预处理后的数据同步适配，提升模型训练的准确性。此外，在调用大模型的时候在 prompt 中进行字数控制也能一定程度上防止关键信息的丢失。

聚焦代码的话，可以新增医学段落拆分与截断函数，替换原 `text[:n]`（`n` 指的是进行硬截断的字数）。由于知识库爬取的数据多包涵前缀，可以根据前缀内容进行分类保证优先级较高的内容优先输出。按肿瘤文本的「定义→病因→症状→治疗→并发症→预后」逻辑，用正则拆分段落，对每个段落做 Token 计数 + 长度限制，核心段落（治疗、并发症）强制完整保留，非核心段落（背景、冗余描述）按需截断。

问题 3：爬虫鲁棒性 示例代码使用了简单的 `requests.get()` 方法。如果全班同时高频运行脚本访问同一个网站，极大概率会触发反爬虫机制。

思考： 在实际的工程爬虫中，我们应该如何提升代码的稳健性并遵守爬虫道德？
（在此填写你们采取的反爬措施和优化思路）

答:

通过 `requests.get(timeout=10)` 设置超时时间，防止请求长时间阻塞导致程序卡死，提升代码容错性；

遍历目标 URL 时，每爬取一个页面后通过 `random.uniform(2, 4)` 设置 2-4 秒随机休眠，避免固定间隔被反爬规则识别；

读取 `data_raw.json` 中已爬取的 `source_url`，跳过重复 URL，避免对同一页面多次请求；

仅爬取网站公开的非付费内容，不尝试突破登录 or 付费墙，不爬取用户隐私数据